

中图法分类号: TP391.41; TN27 文献标识码: A 文章编号: 1006-8961(2024)05-1321-25

论文引用格式: Lin S Y and Wu Y Q. 2024. Vision-based LCD/OLED defect detection methods: a critical summary. Journal of Image and Graphics, 29(05):1321-1345(林思媛, 吴一全. 2024. 基于视觉的液晶屏/OLED屏缺陷检测方法综述. 中国图象图形学报, 29(05):1321-1345)[DOI: 10.11834/jig.230518]

基于视觉的液晶屏/OLED屏缺陷检测方法综述

林思媛, 吴一全*

南京航空航天大学电子信息工程学院, 南京 211106

摘要: 液晶屏(liquid crystal display, LCD)和有机发光半导体(organic light-emitting diode, OLED)屏的制造工艺复杂, 其生产过程的每个阶段会不可避免地引入各种缺陷, 影响产品的视觉效果及用户体验, 甚至出现严重的质量问题。实现快速且精确的缺陷检测是提高产品质量和生产效率的重要手段。本文综述了近20年来基于机器视觉的液晶屏/OLED屏缺陷检测方法。首先给出了液晶屏/OLED屏表面缺陷的定义、分类及其产生的原因和缺陷的量化指标; 指出了基于视觉的液晶屏/OLED屏表面缺陷检测的难点。然后重点阐述了基于图像处理的缺陷检测方法, 包括介绍图像去噪和图像亮度矫正的图像预处理过程; 考虑到所采集的液晶屏/OLED屏图像存在纹理背景干扰, 对重复性纹理背景消除和背景抑制法进行分析; 针对Mura缺陷边缘模糊等特点, 总结改进的缺陷分割方法; 阐述提取图像特征并使用支持向量机、支持向量数据描述和随机森林算法等基于特征识别的缺陷检测方法。接着综述了基于深度学习的缺陷检测方法, 根据产线不同时期的样本数量分别总结了无监督学习、缺陷样本生成、迁移学习和监督学习的方法, 其中无监督学习从基于生成对抗网络和自编码器两个方面进行阐述。随后梳理了通用纹理表面缺陷数据集和模型性能的评价指标。最后针对目前液晶屏/OLED屏缺陷检测方法存在的问题, 对未来进一步的研究方向进行了展望。

关键词: 缺陷检测; 液晶屏(LCD); OLED屏; 机器视觉; 深度学习; 纹理背景消除; 无监督学习

Vision-based LCD/OLED defect detection methods: a critical summary

Lin Siyuan, Wu Yiquan*

College of Electronic and Information Engineering, Nanjing University of Aeronautics and Astronautics, Nanjing 211106, China

Abstract: The new display industry is an important foundation for strategic emerging information industries. Under the active guidance and continuous investment of various national industrial policies, China's new display industry has rapidly developed and has become one of the most dynamic industries. The industry scale accounts for up to 40% of the global display industry, ranking first in the world. Under the background of the current digital information age, the demand for consumer electronics, such as smart phones, tablets, computers, displays, and televisions, in various occasions, is constantly rising. This phenomenon results in a yearly rising trend in the global demand for liquid crystal display (LCD) and organic light-emitting diode (OLED) screens and other display panels. The manufacturing process of LCD and OLED is complex, and every stage of the production process will inevitably produce various defects, affecting the visual effect and user experience and even leading to serious quality problems. Fast and accurate defect detection is crucial to improving product quality and production efficiency. Therefore, the defect detection in the production process of LCD and OLED is

收稿日期: 2023-07-21; 修回日期: 2023-09-28; 预印本日期: 2023-10-05

* 通信作者: 吴一全 nuaaimage@163.com

基金项目: 国家自然科学基金项目(61573183)

Supported by: National Natural Science Foundation of China (61573183)

necessary. This article reviews the research progress of defect detection methods for LCD/OLED based on machine vision in the past 20 years to provide valuable reference. First, the structure and manufacturing process of commonly used TFT-LCD and OLED are given. The defects on the surface of the LCD/OLED are classified in accordance with the causes of defects, defect size, and defect shape. The definitions of the defects are presented, and the causes of the defects are briefly described. The quantitative indicators of defects SEMU and DSEMU are given. The difficulties of surface defect detection of LCD/OLED screens based on machine vision are also explained. This paper focuses on the defect detection methods based on image processing. In actual production, the images to be detected are captured by industrial cameras, and their images are easily affected by noise and light source. First, the image preprocessing of image denoising and image brightness correction is introduced. Then, eliminating the interference of texture background before segmentation and localization of defects is necessary due to the texture background of the collected LCD/OLED images. The repetitive texture background elimination is elaborated, and the defect detection method based on background suppression method is introduced from the three methods of polynomial fitting, discrete cosine transform, and statistical analysis. The measurement standards of background suppression are also presented. Mura defects are characterized by low contrast, blurred edges, and irregular shape. Thus, traditional edge detection and threshold segmentation methods are unsuitable for Mura defect segmentation, and achieving reliable detection of Mura defects is difficult. Therefore, improved defect segmentation methods are introduced in three sections: threshold and cluster segmentation, active contour model-based method, and edge and shape detection. The evaluation indexes of defect segmentation effects are also given. Image features are the most basic attributes that characterize an image. One of the methods of defect detection is extracting and classifying local or global features of images. The defect detection methods based on feature recognition, which extract image features and use traditional machine learning such as support vector machine, support vector data description, fuzzy pattern recognition, and random forest, are explained. Considering the traditional feature extraction method or the classical background reconstruction method, the missing rate of low contrast and small area defects is still substantially high. The traditional defect detection is conducted in multiple steps, which leads to the loss of defect information, resulting in the absence of low contrast defect and restricting the detection accuracy. The poor expression capability of manually extracted features also leads to the limitation of detection accuracy. In recent years, deep learning has achieved remarkable success in object detection, which can achieve fast and accurate target identification and detection. Thus, an increasing number of scholars have applied this method to the defect detection of LCD/OLED. This paper reviews the defect detection methods based on deep learning. According to the number of samples in different periods of production line, unsupervised and supervised learning, as well as transfer learning and defect sample generation methods are summarized. Unsupervised learning based on deep learning includes generative adversarial network and auto-encoder to learn the defect-free samples, reconstruct the defective image in the test, and obtain the residual image for defect detection. Supervised learning requires a large number of defect samples to overcome the problems of texture background interference, different defect sizes, and uneven samples. No public dataset based on display defects is currently available. This paper summarizes a series of general texture surface defect data sets that can be used for texture-based background defect detection, which can be employed for transfer learning and algorithm universality verification, and evaluation indicators of model performance are introduced. Finally, the existing problems in the current LCD/OLED defect detection methods are identified. Complex background problems are still unavoidable in the detection process due to the detection difficulties caused by the characteristics of Mura defects such as low contrast and blurred edges. Limited datasets and real-time algorithm problems are also encountered. The future research direction is prospected, and important research directions in the future include dataset expansion, sample equalization, enhanced algorithm generality, transferable algorithm, deep learning model acceleration, and curved screen defect detection. Such research direction may considerably promote the application of machine vision technology in LCD/OLED defect detection.

Key words: defect detection; liquid crystal display (LCD); organic light emitting diode (OLED); machine vision; deep learning; texture background elimination; unsupervised learning

0 引言

新型显示产业是战略性新兴产业的重要基础,在国家各项产业政策的积极引导和持续投资下,我国新型显示产业飞速发展,已成为最具活力的产业之一,产业规模在全球的显示产业中占比高达40%,位居全球第一。在当前数字信息时代的背景下,智能手机、平板、电脑、显示屏和各类场合中的电视等消费电子产品需求不断上升,致使全球液晶屏(liquid crystal display, LCD)和有机发光半导体(organic light-emitting diode, OLED)屏等显示屏面板需求呈现逐年上升的趋势。液晶屏和OLED屏的制造工艺复杂,流程繁多,其生产过程对环境的要求极为苛刻,在制造的每个阶段都会不可避免地引入点缺陷、线缺陷和Mura缺陷等各种缺陷,影响产品的视觉效果及用户体验,甚至出现严重的质量问题。如何保证产品质量从而提升生产效率,是生产制造商在新型显示产业中提高竞争性不可或缺的重要手段,所以研究液晶屏/OLED屏的缺陷检测有着极为重要的现实意义。

目前国内外生产家常使用的液晶屏/OLED屏缺陷检测方式是专业质检人员通过人眼检测。该检测方法受检测人员主观因素影响,对缺陷检测缺乏客观的量化指标。此外,由于人眼疲劳等因素的影响,人工视觉检验很难进行长时间的检测,且会对检测结果的稳定性产生影响。随着目前液晶屏/OLED屏的生产力提高、面板尺寸多变和分辨率提高,人工目测的方法需要更高的劳动力成本,但是检测效率和准确率低,无法同时满足生产效率和产品质量的要求。除了人工以外的通用缺陷检测方法涵盖更多的技术领域,如电学检测、信号处理、模式识别和自然语言处理等,这些方法可以用于不同类型的数据。由液晶屏或OLED屏的电气缺陷所导致的缺陷,如点缺陷和线缺陷等缺陷可以用电学检测的方法进行检测。常用的电学检测方法有:全屏点亮法、探针扫描法等(简川霞,2015)。电学检测方法的成本较高,使用限制较严,在检测过程中容易造成二次伤害。对于非电气缺陷,使用电气检测的方法无法对其进行检测。视觉的缺陷检测方法是应用最广泛的非电气缺陷检测方法,主要应用于图像、视频等视觉信息的处理,特别关注表面缺陷、形状缺陷等外观问题。

视觉的缺陷检测方法和通用的缺陷检测方法之间存在一些差异,主要体现在其应用领域和技术手段上。首先,视觉的缺陷检测方法侧重于处理图像和视频等视觉数据,对产品的表面瑕疵、形状问题等进行检测。与之相比,通用的缺陷检测方法更具广泛性。其次,视觉的缺陷检测方法在技术手段上主要依赖于图像处理和计算机视觉领域的技术,如边缘检测、特征提取等。近年来流行的基于视觉的液晶屏/OLED屏缺陷检测方法利用图像信息进行缺陷检测,与上述人工视觉检测法和电学检测方法相比,视觉缺陷检测有着检测速度快、无需夹具而成本降低、高精度、非接触所以不会造成二次损伤的优点,可以有效提升生产和检测效率,制造更大的利润空间。点缺陷和线缺陷的对比度很高,具有规则的形状和固定的面积大小,采用机器视觉的方法可以较容易地检测出来。Mura缺陷有着对比度低、无明显边缘和亮度不均匀的特点,是所有液晶屏/OLED屏缺陷中最难检测的显示缺陷之一。目前普遍采用的上述人工视觉方法和电学检测方法都无法对Mura缺陷实现可靠的检测,因此基于机器视觉的Mura缺陷检测方法得到广泛研究,逐渐成为研究热点。在文献中可用的Mura缺陷自动检测(automatic mura defect detection, AMDD)算法中,Pratt等人(1998)提出了业内最知名的算法之一MuraLook™,该算法使用传统的图像处理操作,如卷积滤波、形态滤波和斑点形状分析等操作,系统地分离每种缺陷。但是目前AMDD算法存在的主要问题是缺乏合适的通用算法以适应不同产线 and 大规模生产,需要提高检测速度以实现工厂中的在线质量控制,以及提高检测的精度,使测量的灵敏度必须至少与人眼的灵敏度相当。另外,一些基于视觉的液晶屏/OLED屏缺陷检测商业解决方案也得到了应用,如MuraTool, ELDIM, mura MVP和TrueTest™,它们搭载视觉检测算法、硬件调试设置和用户显示界面等,以实现集成的通用液晶屏/OLED屏缺陷检测,适用于不同的产品与产线。

简川霞(2015)综述了薄膜晶体管液晶显示器(thin film transistor liquid crystal display, TFT-LCD)表面缺陷的检测方法,该综述按照方法进行叙述,但是一些图像处理操作并不局限于某一种方法;此外,该综述发表时间较早,没有涵盖近8年发表的文献。Ming等人(2021)综述了LCD的Mura缺陷检测方法,包括图像预处理以及特征提取与分类,但是通用方

法居多,且方法并不全面,也不系统。除此之外,上述两篇综述均未给出 Mura 缺陷的量化标准,同时均未涉及基于深度学习的 Mura 缺陷检测方法。相较于上述已有的综述,本文综合了液晶屏和 OLED 屏的缺陷的分类和检测算法,并对液晶屏/OLED 屏的缺陷进行了更加详细的分类。本文按照图像处理流程阐述基于背景消除或抑制以及基于特征识别的传统图像处理检测方法,综述了基于深度学习的液晶屏/OLED 屏的缺陷检测方法,并给出评价指标和数据集。

本文详细综述并系统分析了现有的液晶屏/OLED 屏缺陷检测方法,旨在为从事液晶屏/OLED 屏缺陷检测的研究人员提供有价值的参考。

1 液晶屏/OLED 屏结构、缺陷及检测难点

1.1 常用的 TFT-LCD 屏/OLED 屏结构与制程

TFT-LCD 面板由液晶和上下两片玻璃基板组成,彩色滤光片贴合于上层玻璃基板,用于产生颜色,薄膜电晶体(thin film transistor, TFT)镶嵌于下层玻璃基板,控制液晶分子的扭转角度,以改变光线的偏极性。偏光片用于决定像素的明暗状态。背光板为显像提供基本的光源。TFT-LCD 面板的结构如图 1 所示。




图1 TFT-LCD 面板结构

Fig. 1 The structure of TFT-LCD

TFT-LCD 的生产过程按照制程可以分为 Array 段制程、Cell 段制程和 Module 段制程。TFT-LCD 的 Array 制程分为“薄膜、黄光、蚀刻、剥膜”四大部分,将薄膜电晶体制作在玻璃之上。中段的 Cell 制程将 Array 段的玻璃基板与彩色滤光片玻璃基板相结合,并向两块玻璃基板之间灌入液晶。后段 Module 制程进行液晶基板的驱动 IC 压合、印刷电路板和背光部分的整合。

OLED 屏由基板、阴极、阳极、空穴注入层(hole inject layer, HIL)、电子注入层(electron inject layer, EIL)、空穴传输层(hole transport layer, HTL)、电子传输层(electron transport layer, ETL)、电子阻挡层(electron blocking layer, EBL)、空穴阻挡层(hole blocking layer, HBL)和发光层(emissive layer, EML)等部分构成。与 TFT-LCD 不同,它不需要背光板,

而是通过电场驱动有机半导体材料和发光材料,通过载流子注入和复合进行发光。OLED 屏的结构示意图如图 2 所示。

OLED 屏的生产过程也可以分为 Array 段、Cell 段和 Module 段 3 个制程。Array 段进行有机发光材料等材料的蒸镀,结合驱动电路形成发光器件,并在无氧环境中进行封装。Cell 段产生有机镀膜。Module 段进行切割,将背光板、偏光片、驱动芯片和控制线路与基板整合。

TFT-LCD 与 OLED 屏显示面板的制作都包含上百道工序,其中,Cell 段包含的工序最为复杂,是故障和缺陷频发的阶段。

1.2 缺陷的分类、产生原因和量化指标

液晶屏和 OLED 屏同属平板显示器(flat panel display, FPD),虽然工作原理和生产工艺不同,但是




图2 OLED结构示意图

Fig. 2 The structure of OLED

所呈现出来的缺陷可以进行统一的分类和量化。本节按照不同标准对缺陷进行分类,简述液晶屏/OLED屏缺陷的产生原因,并给出Mura缺陷的量化指标。

1. 2. 1 缺陷的分类和产生原因

1)按照缺陷的形成原因进行分类。可以分为电气缺陷和非电气缺陷。电气缺陷由电路的短路、断路、驱动异常和压线不良等电气因素造成(Tsai和Hung, 2005);而非电气缺陷则是由非电气因素造成,如板内有异物,液晶不均匀或涂布不均、划伤等因素。

2)根据缺陷尺寸进行分类。可以分为宏观缺陷和微观缺陷。宏观缺陷包括面板颜色不均匀、污点和错位等,具有尺寸和形状不规则、对比度高和尺寸大的特点;微观缺陷包括面板中的针孔、划痕和颗粒等缺陷,微观缺陷的尺寸很小,不易被发觉(曾毅, 2017)。图3是3种微观缺陷的示意图(图像的分辨率为60像素/mm)。

3)按照缺陷的形状进行分类。可以分为点缺陷、线缺陷和Mura缺陷。点缺陷一般由电气因素产生,如信号线开路或短路、在液晶屏中可能由有缺陷的晶体管产生。点缺陷又可以分为亮点缺陷、暗点缺陷和坏点缺陷。线缺陷定义为液晶屏/OLED屏中某一行或列的连续像素缺陷。按亮度划分可以分为亮线、暗线缺陷。图4是点缺陷和线缺陷的示意图。点缺陷仅占一个屏幕像素点,线缺陷表现为宽度为一个屏幕像素点的线状缺陷。

Mura一词来源于日本,译为斑点、脏污,在英文中用stain、blemish表示,在韩语中用alluk表示(Pratt




图3 微观缺陷示意图(Tsai和Hung, 2005)

Fig. 3 Schematic diagram of microscopic defects (Tsai and Hung, 2005) ((a) pinhole; (b) scratch; (c) particle)




图4 点缺陷和线缺陷示意图(欧阳韬, 2018)

Fig. 4 Schematic diagram of spot and line defects (Ouyang, 2018) ((a) spot defect; (b) line defect)

等,1998),中文可翻译为云纹。国际半导体设备与材料组织(Semiconductor Equipment and Materials International, SEMI)形容Mura缺陷为:显示器工作时,像素矩阵表面可见的不完美显示(SEMI, 2002)。Mura缺陷具有低对比度、亮度不均匀、通常大于单个像素(Pratt等, 1998)和边缘模糊的特点,容易引起人眼视觉感官的不适。Mura缺陷可能产生于液晶屏/OLED屏制造过程的各个阶段,Array段玻璃基板的杂质和划痕容易造成点状和线状的Mura缺陷,涂布不均匀和TFT漏电不均匀会造成带状和区域Mura缺陷这类大面积缺陷;Cell段液晶材料不均匀或镀膜不均匀、偏移会造成重力Mura等区域缺陷;Module段压合偏移或变形也会形成各种区域缺陷。而由于上述Mura缺陷自身的特点,且即使是同一类别的缺陷也可能呈现不同的大小和形状,以及一些类型的Mura缺陷样本稀缺,Mura缺陷的检测一直被认为是最难检测的缺陷之一(梅爽, 2017)。图5显示了8种常见的Mura缺陷(最小的点状Mura缺陷长度仅占3个屏幕像素,而带状Mura缺陷可长达上千个屏幕像素,即使是同类型的Mura缺陷也存在大范围的尺度变化)。

表1—表3列举了不同分类标准下的缺陷类型,并简述了它们的产生原因或特征。




图5 8种常见的Mura缺陷(梅爽,2017)

Fig. 5 Eight common Mura defects (Mei, 2017) ((a) black spot Mura; (b) white spot Mura; (c) line Mura; (d) scratch Mura; (e) gravity Mura; (f) ring Mura; (g) coin Mura; (h) light leakage Mura)

表1 按缺陷形成原因进行分类		
Table 1 Classification by the causes of formation		
缺陷类型	包含缺陷	产生原因
电气缺陷	点缺陷	开路或短路的信号线和扫描线以及有缺陷的晶体管等原因
	线缺陷	
非电气缺陷	Mura缺陷	产生原因复杂,如液晶材料分布不均匀、面板异物、背光源发光不均匀等

表2 按缺陷尺寸进行分类	
Table 2 Classification by defect size	
缺陷类型	包含缺陷
宏观缺陷	面板颜色不均匀
	面板污点
	面板错位
微观缺陷	针孔
	划痕
	颗粒

1. 2. 2 Mura缺陷量化指标

SEMI在SEMI D31-1102标准中,制定了Mura缺陷的量化标准,并将其称之为SEMU标准(SEMI, 2002)。刚好可识别(just noticeable difference, JND)

表3 按缺陷的形状和面积进行分类		
Table 3 Classification by defect shape and area		
缺陷类型	包含缺陷	缺陷形状和面积特点
点缺陷	亮点缺陷	黑屏情况呈现R、G、B点
	暗点缺陷	白屏情况呈现非单纯R、G、B的色点
	坏点缺陷	白屏情况呈现纯黑色的点或黑屏呈现纯白色的点
线缺陷	亮线缺陷	黑屏情况呈现R、G、B线
	暗线缺陷	白屏情况出现非单纯R、G、B的线
Mura缺陷	黑点 Mura	低对比度、边缘模糊、亮度不均匀区域,面积通常大于单个像素
	白点 Mura	
	线 Mura	
	划痕 Mura	
	重力 Mura	
	环状 Mura	
	硬币 Mura	
	漏光 Mura	
	⋮	

表示可觉察和不可觉察的概率均为50%时的统计值(Hecht, 1924), Mura缺陷在JND情况下的对比度与缺陷面积的关系为

$$C_{\text{jnd}} = \frac{1.97}{S_{\text{jnd}}^{0.33}} + 0.72 \quad (1)$$

式中, C_{jnd} 是 JND 时的对比度, S_{jnd} 是 JND 时 Mura 缺陷的面积, 计算式为

$$S_{\text{jnd}} = \frac{N_p}{N} \times S = \frac{\int_{\Omega} H(\varphi(x, y)) dx dy}{N} \times S \quad (2)$$

式中, N_p 表示 Mura 缺陷所占的像素点数, N 为图像的总像素点数, $\varphi(x, y)$ 表示待检测图像, $H(\varphi(x, y))$ 表示图像中的 Mura 缺陷区域, S 为液晶屏/OLED 屏的实际面积。SEMU 标准的计算式为

$$f_{\text{SEMU}} = \frac{|C_x|}{C_{\text{jnd}}} = \frac{|C_x|}{\frac{1.97}{S_{\text{jnd}}^{0.33}} + 0.72} \quad (3)$$

式中, $|C_x|$ 表示检测所得的 Mura 缺陷平均对比度。 $|C_x|$ 的计算式为

$$|C_x| = \frac{|c_o - c_b|}{c_b} \times 100\% \quad (4)$$

式中, c_o 是 Mura 缺陷的平均灰度, c_b 是背景的平均灰度。缺陷的严重等级随着 SEMU 值增大而增大, SEMU 值大于 1 时, Mura 缺陷存在且较为明显。Mura 缺陷的等级根据人的视觉感受进行划分, 观测距离也会极大地影响视觉感受, SEMU 标准只考虑了 Mura 缺陷的对比度和面积, 因此有一定的局限性。为了进一步完善 Mura 缺陷的量化标准, 日本平板显示器计量委员会基于 SEMU 标准进行修正, 提出了 DSEMU 指标(卢小鹏, 2014), 并通过大量实验论证了 DSEMU 标准的准确性与可靠性。DSEMU 引入观测距离对 C_{jnd} 进行重新定义, 其表达式为

$$C_{\text{jnd}} = \frac{2.2K}{d^{0.33}} \quad (5)$$

式中, d 为缺陷长轴, 即 Mura 缺陷的最小外接圆直径, K 为距离系数, 计算式为

$$K = 0.2D^2 - 0.2D + 1 \quad (6)$$

式中, D 为观测距离, 即采集图像时, 相机距离显示屏的距离, 单位为 m。DSEMU 的定义为

$$f_{\text{DSEMU}} = \frac{|C_x|}{C_{\text{jnd}}} = \frac{|C_x| d^{0.33}}{2.2K} \quad (7)$$

式中, $|C_x|$ 表示检测所得的 Mura 缺陷平均对比度。一般将 DSEMU 值划分为 3 个等级用于 Mura 缺陷等级的划分, 当 DSEMU 值小于 2.5 时, 定义 Mura 缺陷为 P 级, 此时 Mura 缺陷可以忽略; 一般 Mura 缺陷定义为 NG, 此时 DSEMU 值在 2.5 和 3.5 之间; 严重

Mura 缺陷定义为 V 级, DSEMU 值大于 3.5(卢小鹏, 2014)。

1.3 基于机器视觉缺陷检测的难点

基于机器视觉的液晶屏/OLED 屏缺陷检测难点主要有以下 5 个方面:

1) 重复的纹理背景。采集到的液晶屏/OLED 屏图像存在重复的纹理背景, 这将影响后续缺陷分割的效果, 无法实现缺陷与背景的有效分离。

2) 整体亮度不均匀。液晶屏使用背光源为显像提供基本的光源, 背光源光照的不均匀性会导致采集到的图像整体亮度不均匀。OLED 屏无需背光源, 采用自发光的方式显示图像, 但是受采集时光照变化的影响, 以及各 OLED 屏样本的材质不同, 采集到的图像同样会出现整体亮度不均匀的问题。

3) Mura 缺陷具有对比度低、边缘模糊的特点, 导致传统的缺陷分割方法很难直接应用到 Mura 缺陷的检测中, 需要找到更合适的分割缺陷的方法。

4) 检测结果应符合人眼的视觉特性, 能够对缺陷进行量化和缺陷等级划分。

5) 检测方法应具有鲁棒性, 可以适应噪声、光照等环境干扰; 能够实现在线自动检测, 无需中途干预, 提高效率。

2 基于图像处理的缺陷检测方法

在实际生产中, 待检测的图像由工业相机拍摄所得, 其成像极易受到噪声和光源的影响, 本节首先介绍图像去噪和图像亮度矫正; 同时针对液晶屏/OLED 屏具有的纹理背景特征, 详细阐述纹理背景消除和基于背景抑制法的缺陷检测方法, 给出背景抑制的衡量标准; 由于 Mura 缺陷具有低对比度、边缘模糊和形状不规则的特点, 使用传统的阈值分割和边缘检测等方法无法对 Mura 缺陷进行可靠检测, 因此总结了针对液晶屏/OLED 屏的改进缺陷分割方法; 最后综述基于特征提取和分类的缺陷检测方法。

2.1 图像去噪和背景亮度不均匀矫正

在使用图像传感器 CCD(charge-coupled device) 和 CMOS(complementary metal oxide semiconductor) 采集图像的过程中会引入各种噪声, 图像去噪是图像增强的重要手段, 可以在图像的空间域或变换域中完成。在空间域中, 张昱和张健(2006a)采用图像平均的方法, 但该方法占用大量内存和处理时间。

在变换域中, Nakano 和 Mori (2005) 使用 Symmetric Selesnick 小波变换的多分辨率分析去噪, 但会不可避免地会将点缺陷误为噪声去除。

不均匀的光照条件和液晶屏自身发光等原因, 会导致采集到的图像亮度不均匀, 形成图像的总体亮度偏差, 这严重影响了对缺陷的检测。为提高缺陷分割的准确率, 需要对亮度进行校正。空间域中, Taniguchi 等人 (2007) 运用灰度线性映射的方法对图像亮度进行增强, 但该算法容易造成图像过增强, 丢失图像中大量有用信息。Shuai 等人 (2022) 将色差转为亮度差, 提出一种自适应变间隔伽马矫正方法, 进行亮度均衡。在变换域中, Tsai 和 Hung (2005) 使用 Haar 小波变换消除不均匀照明, 但需要对图像特征有一定的先验知识以实现滤波器类型和参数的恰当选择。毕昕和丁汉 (2010) 结合同态变换和独立成分分析 (independent component analysis, ICA) 对亮度进行自适应校正, 但是该算法的校正结果不稳定。

2.2 重复性纹理背景消除和背景抑制法

2.2.1 重复性纹理背景消除

由于液晶屏和 OLED 屏内部均由均匀排列的像素矩阵构成, 在采集的时候很容易引入莫尔条纹。背景的光照不均匀和纹理背景导致采用传统阈值分割和边缘检测方法很难对缺陷实现准确分割。

在变换域中, Li 和 Tsai (2011) 将纹理背景看做图像频域中的高能量频率, 利用一维霍夫变换 (Hough transform, HT) 对其进行检测并将高能量频率分量置零, 但该方法对图像旋转敏感。Tsai 等人 (2007) 将纹理背景看做频域中的周期性峰值并将其滤除, 该算法能明显保留异常但是对噪声敏感。张腾达等人 (2016) 将纹理看做频域中的高能量部分, 提出一种基于二维离散傅里叶变换 (discrete Fourier transform, DFT) 的算法, 在频域使用霍夫变换检测高能量频域直线并将其置零。王宏硕和杨永跃 (2018) 结合二维 DFT 与显著性模型检测频谱图中的高能量频率成分并消除。这类算法对噪声和旋转不敏感, 但是傅里叶变换无法进行局部分析, 因此在对灰度局部不均匀的图像重构时效果不佳。小波变换有着多分辨率分析的特点, Oh 等人 (2007) 提出一种基于小波变换和人眼视觉特性的 TFT-LCD 缺陷检测算法。毕昕和丁汉 (2010) 设计了不同中心频率和滤波方向的 Gabor 小波滤波器模拟人眼实现图像纹

理背景抑制。

在空间域中, Lu 和 Tsai (2005) 对图像进行奇异值分解 (singular value decomposition, SVD), 将代表背景的奇异值去除, 但是该算法的自适应度低。汪永勇等人 (2021) 采用基于相对总变差模型的图像结构提取方法有效地抑制背景纹理, 并保留了缺陷结构, 但是该方法无法准确地对位于面板边缘的缺陷进行检测。杨勃等人 (2022) 采用空间多尺度显著性缺陷提取算法, 适用于不同尺寸缺陷的检测, 但是算法通用性较差。严成宸等人 (2017) 选取待检测图像左上角矩形区域构建加权模板消除纹理, 该算法原理简单, 但自适应差。重复性纹理背景消除的方法对比如表 4 所示。

2.2.2 背景抑制法

背景抑制法的关键是拟合无缺陷的背景图像, 获得与待检测图像做差分运算的模板图像。

1) 多项式拟合。张昱和张健 (2006a) 使用基于最小二乘法的多项式曲面拟合技术进行背景拟合。然而随着多项式阶数的增加, 通过多项式曲面拟合所得的背景极易产生龙格现象。李坤等人 (2014) 为了消除多项式拟合过程中的龙格现象采用改进的双三次 B 样条曲面拟合算法, 但是需要人为设定系数。使用最小二乘法处理的拟合背景与原始图像过于相似, 会导致 Mura 缺陷的漏检, Lee 和 Yoo (2004) 提出了一种改进的基于回归拟合的方法来重建图像背景, 但是此类方法检测效率不高, 且存在大尺度 Mura 缺陷漏检测问题。

2) 基于离散余弦变换。Chen 和 Kuo (2008) 基于离散余弦变换 (discrete cosine transform, DCT) 进行背景建模, 设计低通滤波器保留背景部分。该算法计算简单, 但易受亮度不均匀和复杂光照影响。Jin 等人 (2018) 在 Chen 和 Kuo (2008) 的基础上提出一种基于 DCT 和对偶 γ 分段指数变换的检测方法, 增强 Mura 缺陷区域以提高缺陷与背景之间的对比度。

3) 基于统计分析。基于统计分析的背景重构方法有矩阵分解、主成分分析和独立成分分析等方法。Cen 等人 (2015) 假设液晶屏的纹理背景图像为一个低秩矩阵, 利用低秩矩阵分解重构图像背景以检测 Mura 缺陷。谢瑞等人 (2016) 对图像进行奇异值分解, 利用最大熵选择有效奇异值对图像背景进行重建。但是奇异值分解的求解以正交基为基础,

表4 重复性纹理背景消除主要方法对比

Table 4 Comparison of main methods for repetitive texture background elimination

类别	方法	具体方法	优点	局限性
变换域	Li和Tsai(2011)	一维霍夫变换检测高能量频率分量并置零	能明显保留异常	自适应差,对旋转敏感
	Tsai等人(2007)	滤除一维傅里叶光谱中的周期性峰值	能明显保留异常	对噪声敏感
	张腾达等人(2016)、王宏硕和杨永跃(2018)	利用霍夫变换或显著性模型检测二维DFT频域中高能量频率分量	对噪声和旋转不敏感	对于灰度的局部不均匀不能很好地重构
	毕昕和丁汉(2010)	不同滤波方向和中心频率的Gabor小波滤波器	多分辨率分析,符合人眼的视觉特性	自适应度低
空间域	Lu和Tsai(2005)	进行奇异值分解,将代表背景的奇异值去除	复原的缺陷和背景对比度高	自适应度低
	汪永勇等人(2021)	使用基于相对总变差模型的图像结构提取方法	能有效且完整地保留缺陷	无法对位于面板边缘的缺陷进行准确的检测

因此对于非水平和垂直方向的纹理抑制效果不佳。Yun等人(2014)对检测图像进行主成分分析(principal component analysis, PCA),保留前 k 个主成分后对背景图像进行重构。但是PCA方法基于高斯分布的假设来处理数据,并未考虑到待检测图像的非高斯数据。Lu和Tsai(2008)将ICA应用于无缺陷的训练图像中,训练解混矩阵和对应的独立分量。但该方法不能很好地适应液晶屏复杂背景的重构。Wang等人(2016)提出了一种基于ICA背景重建和多通道融合的图像缺陷检测方法。该方法对含有不同大小和类型的Mura缺陷的检测具有较强的鲁棒性。

4) 背景重建效果评价。Jin等人(2018)将理想的背景重建概括为无噪、无损和增强,并给出定义式。无噪是指重建的背景没有引入新的噪声干扰;无损是指经重建的背景图像被抑制后,不损失缺陷的信息;增强是指背景抑制后,缺陷与背景的对比度得到增强,缺陷更加明显,可视性得到提高。

(1) 无噪的量化值 L 可以通过重建后的背景与标准背景的平均灰度差值定义,具体为

$$L = \frac{1}{num} \left| \sum \sum (I_{sb}(x, y) - I_B(x, y)) \right| \quad (8)$$

式中, I_{sb} 为标准背景图像,即相同采集条件下获得的无缺陷图像, I_B 为背景重建后的背景图像, num 为统计的灰度非零像素个数。

(2) 无损可以通过获得缺陷面积 A 进行评价,具体为

$$A = \sum_{(I(x,y) - I_B(x,y)) \in D} s(x, y) \quad (9)$$

式中, I 为待检测的缺陷图像, $s(x, y)$ 为单元像素的面积, D 表示满足缺陷区域内差值不为0的像素域。

(3) 增强 C 可以通过缺陷与背景的平均对比度来定义,具体为

$$C = \frac{|L_M - L_B|}{L_B} \quad (10)$$

式中, L_M 和 L_B 分别表示算法处理后缺陷区域和背景的平均灰度值。背景抑制法主要方法的对比如表5所示。

2.2节主要介绍了重复性纹理背景消除和背景抑制法,其不同在于前者通过检测纹理背景部分并消除,后者注重拟合无缺陷背景图像,并通过差分去除纹理背景。在消除纹理背景干扰后,获得对比度更高的缺陷图像以进行进一步操作。

2.3 缺陷分割

在消除背景的不均匀和纹理背景之后,需要进行图像分割将目标缺陷与背景分离。由于Mura缺陷本身的特性,传统的边缘检测和阈值分割等方法并不适用于Mura缺陷的分割并且很难实现缺陷的可靠检测。本节将从阈值分割和聚类分割、基于活动轮廓模型的方法、边缘检测和形状检测3部分介绍改进算法,并给出缺陷分割的效果评价指标。

2.3.1 阈值分割和聚类分割

阈值分割将灰度图像转化为二值图像实现缺陷与背景的分离。由于Mura缺陷边缘模糊,对比度低,传统的阈值分割很难实现很好的分割效果。

表5 背景抑制法主要方法对比
Table 5 Comparison of main methods of background suppression

类别	方法	具体内容	优点	局限性
多项式拟合	张昱和张健(2006a)	基于最小二乘法的多项式曲面拟合	算法简单	阶数增大容易产生龙格现象,拟合背景与原始图像过于相似
	李坤等人(2014)	改进的双三次B样条曲面拟合算法	可以消除龙格现象	自适应度低
基于离散余弦变换	Chen和Kuo(2008)	基于离散余弦变换的背景建模方法	计算简单,具有较好的实时性	易受亮度不均匀和复杂光照影响
	Jin等人(2018)	基于DCT和对偶 γ 分段指数变换	增强缺陷和背景直接的对比度	-
基于统计分析	Cen等人(2015)	低秩矩阵分解重构	对光照和缺陷类型具有鲁棒性	-
	谢瑞等人(2016)	基于SVD和最大熵的方法	低噪和高对比度	非水平和垂直方向的纹理抑制不佳
	Yun等人(2014)	主成分分析	-	并未考虑非高斯数据

注:“-”表示该项内容为空。

He和Sun(2015)基于直方图对OTSU阈值分割法进行改进,但是该方法只能检测几种缺陷,并且难以检测小面积Mura缺陷。钱基德等人(2018)使用最大稳定极值区域进行自适应阈值分割,该算法能适应多尺度的缺陷,但是对位于面板边缘的缺陷存在误报。Bhalla和Huang(2021)计算原始图像和增强图像的总方差最小值和均值最小值作为图像的阈值因子,将图像分为背景和前景。最后,将阈值图像与掩码图像进行像素乘,得到二值化的缺陷图像。

聚类分割的思想是对图像的灰度或色度进行合并以实现分割,将模糊引入聚类算法,可以使聚类更接近真实情况。简川霞等人(2021)使用模糊C均值聚类算法(fuzzy C-means clustering, FCM)将缺陷与背景分割出来,FCM具有良好的收敛性且复杂度低,但也存在对初始值和噪声敏感,迭代时容易陷入局部最小的缺点。

2.3.2 基于活动轮廓模型的方法

Chan-Vese模型(C-V模型)是典型的区域主动轮廓模型,但并不适用于强度不均匀的图像,同时其搜索空间大,耗时长,无法应用于在线显示检测。Bi等人(2009)将轮廓内外的亮度差项引入C-V模型,以平衡图像整体亮度的不均匀,提高了分割的准确性,但是对小面积Mura缺陷存在漏检的问题。在此基

础上,卢小鹏等人(2014)将水平集函数与符号距离函数的偏差作为能量项引入C-V模型,解决了符号距离函数重初始化的问题,同时采用无条件稳定的半隐差分格式,适当加大步长以加快分割速度。

局部二值拟合(local binary fitting, LBF)模型利用高斯核函数提取图像的局部灰度信息构造能量方程,因此LBF模型适用于灰度不均匀图像的分割(Li等,2007,2008),但是LBF模型对图像轮廓初始化较敏感。Gan和Zhao(2013)提出了一种改进的LBF模型,该模型对初始轮廓具有鲁棒性,用于提取缺陷边界。但是对于强灰度不均匀的图像,使用单一高斯核函数无法实现很好的分割。

针对基于区域的活动轮廓模型存在的小面积Mura缺陷漏检的情况,Yang等人(2018a)提出区域梯度变分水平集,设计通用和鲁棒的能量函数,该算法可以快速地检测出多类型缺陷,但仍需进一步优化,以提高处理速度。

2.3.3 边缘检测和形状检测

Tuyen Le等人(2020)利用基于局部能量的边缘检测器提取缺陷边缘,不需要参数调谐,对噪声灵敏度低,具有高的各向同性,但是使用颜色进行分割易受光照影响。

标准霍夫变换在低对比度、不均匀照明图像中表现不佳。Li和Tsai(2011)提出一种修正版HT用

于非平稳剖面上的灰度轮廓线检测,得到非平稳灰度轮廓中最可能的线性方程后,灰度轮廓上明显远

离拟合线的任何点即被识别为有缺陷的点。缺陷分割方法的对比如表6所示。

表6 缺陷分割主要方法对比
Table 6 Comparison of main defect segmentation methods

类别	方法	具体方式	优点	局限性
阈值分割	He 和 Sun(2015)	基于直方图的改进 OTSU 阈值分割	设计简单	对小面积缺陷检测不稳定
	钱基德等人(2018)	基于最大稳定极值区域自适应分割	设计简单	位于图像边缘的缺陷存在误报
聚类分割	简川霞等人(2021)	模糊C均值聚类算法	易收敛,复杂度低	对初始值和噪声敏感
活动轮廓模型	卢小鹏等人(2014)	C-V模型引入水平集函数与符号距离函数的偏差	改善小面积缺陷漏检	—
	Gan 和 Zhao(2013)	改进的LBF模型	对初始轮廓具有鲁棒性	不适用于强亮度不均匀图像
	Yang 等人(2018a)	基于区域梯度的水平集的算法	改善小面积缺陷漏检	处理速度不够快
边缘检测	Tuyen Le 等人(2020)	基于局部自适应能量的边缘检测	不需要参数调谐,噪声不敏感,具有高的各向同性	易受光照影响
形状检测	Li 和 Tsai(2011)	修正霍夫变换	适于低对比度和光照不均匀图像	—

注:“—”表示该项内容为空。

2.3.4 缺陷分割效果评价

1) 误分类误差(misclassification error, ME)用于比较分割的准确性,表示被错误分类为目标的背景元素的百分比(Jin 等,2018)。具体为

$$ME = 1 - \frac{|B_c \cap B_s| + |M_c \cap M_s|}{|B_c| + |M_c|} \quad (11)$$

式中, B_c 和 M_c 分别表示检测图像的正确背景和目標缺陷像素, B_s 和 M_s 分别表示分割图像中的背景像素和目標缺陷像素。 ME 值越低,检测精度越高。

2) 计算时间 t 。

3) 鲁棒性评估。为了验证算法在不同条件下的鲁棒性,可以通过设置对照实验,计算从背景中分割出来的缺陷的面积,根据式(12)(13)计算标准差 σ 和相对标准差 RSD ,对鲁棒性进行评估,相对标准差越小,则所提出算法的鲁棒性越高(Jin 等,2018)。具体为

$$\sigma = \sqrt{\frac{\sum_{i=1}^n \Delta s_i^2}{n-1}} \quad (12)$$

$$RSD = \frac{\sigma}{\bar{s}} \quad (13)$$

式中, $\Delta s_i = s_i - \bar{s}$, s_i 表示每个从背景中分割出来的

缺陷的面积, $\bar{s}$ 表示缺陷的平均面积,这些区域以像素为单位,测试样本图像的数量为 n 。

2.3节总结了液晶屏/OLED屏表面缺陷分割的方法,基于阈值分割和聚类分割的方法设计简单但是前者实时性低且自适应性差,后者对初始值和噪声敏感;基于活动轮廓模型的方法被大量学者使用,它具有较好的分割效果但也存在漏检、速度慢的问题;基于边缘检测和形状检测的方法经过改进后,可以改善噪声和光照干扰的问题。

2.4 基于特征识别的缺陷检测方法

基于特征识别的液晶屏/OLED屏缺陷检测方法首先提取缺陷和背景图像的特征,随后使用分类器实现液晶屏/OLED屏缺陷的检测。本节首先简要阐述了图像的局部与全局特征,随后按照特征提取和缺陷分类两部分综述基于特征识别的缺陷检测方法。

2.4.1 特征提取

对图像而言,特征是能够区别于其他类图像的自身特征,一般可分为如下4类:1) 直观性特征。例如边缘、面积和纹理等;2) 灰度统计特征。例如灰度直方图特征、二阶矩特征和不变矩特征等;3) 变换系数特征,即先对图像进行傅里叶变换或小波变

换等后提取特征;4)代数特征,即对图像进行各种代数变换所得到的特征。边缘、色彩等特征可以直观感受,只能代表局部图像的特征,识别的速度快;矩、直方图等特征能够表示完整的图像信息,可以获得更高的识别精度,但是所需处理的数据量大、识别速度较慢。

部分算法利用局部特征检测液晶屏/OLED屏缺陷。张昱和张健(2006b)选取 Mura 缺陷的对比度、面积、轮廓、位置、形状和灰度均匀性这 6 个特征量建立模糊专家系统,但是该算法的速度并不能满足实时检测的要求。一些学者使用高斯拉普拉斯(Laplacian of Gaussian, LOG)滤波器提取缺陷的形状特征,对群 Mura、漏光 Mura、痕 Mura 和垂直带 Mura 进行检测(Fang 等,2006;Chen 等,2005)。

部分研究提取图像的全局特征进行缺陷检测。Chen 和 Chou(2008)提出利用小波变换与离散余弦变换提取全局频域特征区分 Mura 缺陷,该方法不适用于低对比度和大面积的 Mura 缺陷的检测。Tsai 等人(2006)提出了基于约束性 ICA 模型的卷积滤波法,提取背景图像的特征性源强度,但是该方法对噪声和背景不均匀敏感,无法检测出较大尺寸的缺陷。一些方法通过代数变换提取图像的代数特征,Liu 等人(2008)使用局部线性嵌入法(locally linear embedding, LLE)以无监督的方式提供非线性降维。Liu 等人(2009b)还提出基于核主成分分析(kernel principal component analysis, KPCA)的非线性降维方法,提取图像特征并分类。Kang 等人(2009)使用 PCA 和线性判别分析法(linear discriminant analysis, LDA)对图像特征进行降维,该算法对噪声不敏感,

分类速度也有所提高。特征提取主要方法的对比如表 7 所示。

2.4.2 缺陷分类

分类器将提取的特征作为输入,并构造输入与类别的映射,从而实现目标的分类。

Jazi 等人(2012)利用模拟退火(simulated annealing, SA)对支持向量机(support vector machine, SVM)的参数进行优化,提高了分类性能。由于液晶屏/OLED 屏数据集存在样本不均衡的问题,负样本的数量有限,使用 SVM 时,由于正类的间隔很大,会导致误分类。支持向量数据描述(support vector data description, SVDD)通过求解约束优化问题可以有效解决上述问题。为解决 SVDD 中异常值引起的过拟合和多聚类分布问题,Liu 等人(2009a)提出模糊 SVDD;为改善测试时间复杂度,Liu 等人(2011)继续提出了快速 SVDD;为进一步提高泛化性能,Liu 和 Chen(2011)提出了拟共形核 SVDD。液晶屏/OLED 屏表面缺陷对比度低且没有明显边界,存在一定的模糊性,使用模糊模式识别可以用于检测缺陷。张昱和张健(2006b)引入模糊理论建立模糊专家系统以检测 TFT-LCD 缺陷评估,但是评估过分依赖于所制定的模糊规则。Torres 等人(2021)提出一种基于直方图相似性和随机森林算法的 Mura 缺陷检测系统,获得很高的检测准确率,但当决策树变多时,算法的实时性会成为问题。曾毅(2017)提取疑似缺陷区域的灰度特征作为 BP 神经网络的输入,解决候选区域是否为缺陷的二分类问题,该算法计算量小,实时性高。缺陷分类方法的对比如表 8 所示。

表 7 特征提取主要方法对比
Table 7 Comparison of main methods for feature extraction

类别	方法	提取特征	优点	局限性
局部特征	张昱和张健(2006b)	对比度、面积、轮廓、位置、形状和灰度均匀性	特征可以直观感受,识别速度快	无法满足实时检测要求
	Fang 等人(2006);Chen 等人(2005)	形状特征		检测缺陷类型有限
全局特征	Chen 和 Chou(2008)	全局频域特征	适用于高对比缺陷检测	低对比度和大面积缺陷漏检
	Tsai 等人(2006)	特征性源强度	设计思路简单	对噪声和背景不均匀敏感,不适用于检测大面积缺陷
	Liu 等人(2008,2009b);Kang 等人(2009)	图像降维	计算开销小,效率高	自适应差

表 8 缺陷分类主要方法对比

Table 8 Comparison of main methods for defect classification

类别	方法	具体方式	优点	局限性
SVD	Jazi 等人(2012)	利用 SA 优化 SVM	优化参数	样本不均衡,容易导致误分类
SVDD	Liu 等人(2009a);Liu 等人(2011);Liu 和 Chen(2011)	模糊 SVDD、快速 SVDD 拟共形核 SVDD	解决 SVM 误分类问题	—
模糊模式识别	张昱和张健(2006)	建立模糊专家系统	能够进行定量评估	评估过分依赖规则
集成学习	Torres 等人(2021)	随机森林算法	准确率高,不容易过拟合	实时性问题
神经网络	曾毅(2017)	BP 神经网络	计算量小,实时性高	收敛慢,容易陷入局部最小值

注:“—”表示该项内容为空。

2.4 节主要介绍了液晶屏/OLED 屏的特征提取,使用局部特征可以获得更快的检测速度,但是不能表示完整的图像信息;全局特征则因数据量大导致检测速度下降。阐述了基于 SVM 的缺陷分类方法,由于液晶屏/OLED 屏缺陷样本不均衡的问题,提出更适用的 SVDD 方法,基于模糊模式识别、集成学习和浅神经网络的方法也被应用于液晶屏/OLED 屏缺陷分类。

3 缺陷检测中的深度学习网络

事实上,无论是传统的特征提取方法还是经典的背景重构方法,对低对比度缺陷和小面积缺陷的漏检率仍然很高。传统的缺陷检测分多步进行,这会导致缺陷的信息损失,造成低对比度缺陷漏检,从而制约检测精度;手工提取的特征表达能力不强也导致检测精度受限。深度学习在计算机视觉任务,包括图像识别(He 等,2016;Krizhevsky 等,2017;Tan 和 Le,2019)、目标检测(Ren 等,2017;Liu 等,2016;Redmon 等,2016;Tan 等,2020;Lin 等,2020;Huang 等,2017)和图像语义分割(Shelhamer 等,2017;Ronneberger 等,2015;Badrinarayanan 等,2017;Lee 等,2019;Xie 等,2021)等中取得了巨大的成功,可以实现快速且精确的目标识别与检测,越来越多的学者将其应用到液晶屏/OLED 屏的缺陷检测。

3.1 无监督学习

在产线的初期,因缺陷数量有限,很难立刻建立起有效数量的缺陷训练样本,而监督学习以大量的样本数据为驱动,此时,使用基于无监督学习的深度

学习是解决无缺陷训练样本或少样本情形下缺陷检测的方法。通过无监督学习提取的特征相比于监督学习更近似于人脑对事物的理解和认知过程,并且更适合无法获取大量训练样本的场合。由于部分液晶屏/OLED 屏缺陷的样本稀缺以及产线初期资源有限,很难收集到大量且丰富的训练样本,因此将无监督学习应用于液晶屏/OLED 屏缺陷检测具有重要意义。基于深度学习的无监督学习包括生成对抗网络(generative adversarial network, GAN)(Goodfellow 等,2020)和自编码器(autoencoder, AE)(Hinton 和 Salakhutdinov,2006)。图 6 为基于生成对抗网络和自编码器进行缺陷检测的原理图。

基于 GAN 的异常检测学习无缺陷样本的分布,测试时有缺陷的输入图像输出为无缺陷的背景图像,与原图的残差图像用于检测缺陷。Song 等人(2021b)为了解决数据不平衡以及 Mura 的形状和尺寸多变的问题,提出了 Res-unetGAN 网络,它可以基于生成对抗网络对条纹和线形 Mura 进行无监督异常检测,具有很好的检测精度。但是只能针对条纹和线形 Mura 进行检测,缺乏广泛应用的可能。刘强(2020)使用改进 Pix2pix 模型训练人工生成缺陷的良品样本,输出背景图像。在测试中,获得检测图像恢复的背景图像后,通过对比两张图片的灰度值检测缺陷,该方法有良好的检出率但是检测速度较慢。

基于 AE 的异常检测也广泛应用于工业缺陷检测和视频异常检测(梁家菲 等,2023)。基于 AE 的方法通过编码器学习输入样本的隐含特征,解码器利用学习到的新特征重构原始输入,原图像与重构




图6 基于GAN和AE的缺陷检测原理图

Fig. 6 Defect detection schematic based on GAN and AE

图像的残差图像即可用于缺陷检测。Mei 等人(2017)提出一种多模态联合特征表示缺陷特征提取模型(joint-feature representation-based defect recognition framework, JFR-DRF),融合人工提取的特征与无监督学习的特征,获取有效、充分的Mura缺陷特征。代朝东等人(2021)使用卷积去噪自编码器构建多尺度特征进行图像重构,并结合L1损失函数和结构相似性(structural similarity, SSIM)损失函数对模型的损失函数进行改进,极大地提高了重构性能。Mei 等人(2018)提出多尺度卷积去噪自编码器网络(multiscale convolutional denoising autoencoder network, MSCDAE),实现多尺度Mura缺陷的检测。自编码器通常使用滑动窗口来检测纹理缺陷,这会产生大量的图像块,导致计算冗余,效率很低,并不适用于在线检测。Yang 等人(2019)在MSCDAE的基础上提出多尺度特征聚类的全卷积自编码器(multi-scale feature-clustering-based fully convolutional AE, MS-FCAE),利用多重全卷积自编码器提高背景重构性能。检测结果表明,MS-FCAE能够准确地检测TFT-LCD多种类型的缺陷,而其他缺陷检测方法仅适用于某些类型的缺陷。

无缺陷样本情形下液晶屏/OLED屏缺陷检测的关键是实现纹理背景的精确重构,这需要精确抑制缺陷区域的重构。Yang 等人(2021)使用像素级的对抗性学习提高纹理背景重构的准确性,相较于

MS-FACE在检测精度上有所提高,在自建数据集上F1-measure值提高0.128。宋开友(2021)将多尺度特征编码为全局纹理特征,抵抗背景的干扰实现精确的纹理背景重构,相较于MS-FACE在检测精度上有所提高,在自建数据集上F1-measure值提高0.103,缺陷检测结果如图7所示。因使用自建数据集,表9展示了无监督学习方法横向检测性能描述和效率比较结果。

3.2 缺陷样本生成

由于缺陷屏相较于良品屏的数量较少,同时Mura缺陷需要专业的质检人员对其进行收集和标注,这会耗费大量的人力和时间,因此收集液晶屏/OLED屏缺陷数据集十分困难,导致产线早期难以建立大规模的缺陷数据集。一些学者通过少量缺陷样本生成大量合成缺陷图像实现样本的扩充。

Liu 等人(2022)通过生成对抗网络生成缺陷样本进行样本数据集的扩展,对其进行手工标注后使用Mask R-CNN(mask region-based convolutional neural network)进行缺陷的检测与分割。但是该方法需要进行像素级的标注,标注成本高。Tsai 等人(2021)提出一个两阶段的深度学习方案,在第1阶段使用两个循环一致对抗网络(自动合成和注释图像中的缺陷像素,作为第2阶段U-Net训练网络的输入。该方法只需要少量样本,并且解决了缺陷分割时烦琐复杂的逐像素手动注释工作的问题。Lu 和




图 7 Mura 缺陷样本检测结果(宋开友, 2021)
Fig. 7 Mura defect detection results(Song, 2021)

表 9 无监督学习方法检测性能和效率比较
Table 9 Comparison of performance and efficiency of unsupervised learning methods

方法	设备	检测图像 /像素	帧速率/ (帧/s)	检测性能描述或比较
Song 等人(2021b)	NVIDIA GTX 1080 GPU	128 × 128	275	训练数据集 Mura 缺陷样本与无缺陷样本比例为 70% 时, 可达到最高的 AUC, 为 0.995
刘强(2020)	intel(R) Core(TM) i7-9700f 处理器, 32 GB 内存, NVIDIA GeForce RTX 2080Ti, 11 GB 显存	512 × 512	0.65	对点、线缺陷有良好的检出率, 分别为 95% 和 96%, Mura 缺陷的检出率相较于原 pix2pix 模型提高了 12%, 为 94%
Mei 等人(2017)	—	—	—	缺陷识别率相较于仅人工提取和非监督学习提升 20% 和 30%
Mei 等人(2018)	32 GB 内存, GPU 为 GTX 980Ti Nvidia	512 × 512	1.5	F1-measure 值为 0.627 9, 相较于传统的 LCA 和 PHOT (Aiger 和 Talbot, 2010) 算法提升 0.150 6 和 0.412 2
Yang 等人(2019)	Intel Xeon E5-2600 v3 处理器, 64 GB 内存, 4 块 Nvidia Titan Xp GPU	512 × 512	59.6	F1-measure 值为 0.830, 相较于传统的 LCA、PHOT 和 TEXEMS(Xie 和 Mirmehdi, 2007) 算法提升 0.313、0.485 和 0.261, 相比于 Mei 等人(2018) 提升 0.204
代朝东等人(2021)	intel i7-9750H 处理器, 16 GB 内存, GPU 为 GTX 1660Ti, 显存为 6 GB	256 × 256	27	F1-measure 值为 0.944 6, 相较于 Mei 等人(2018) 方法提升 0.011 3
Yang 等人(2021)	—	—	—	F1-measure 值为 0.867, 相较于传统的 PHOT 和 TEXEMS 算法提升 0.415 和 0.311, 相比于 Yang 等人(2019) 方法提升 0.128
宋开友(2021)	Intel Xeon E5-2600 v3 处理器, 64 GB 内存, 2 块 Nvidia Titan Xp GPU	2 436 × 1 125	5.5	F1-measure 值为 0.789, 相较于传统的 PHOT 和 TEXEMS 算法提升 0.486 和 0.445, 相比于 Yang 等人(2019) 方法提升 0.103

注: “—”表示该项内容为空。

Su(2021)使用深度卷积生成对抗网络(deep convolutional generative adversarial network, DCGAN)实现缺陷样本的生成,所生成的样本与真实的样本十分相似。Song 等人(2022)利用多个二维高斯分布产生缺

陷,与无缺陷样本复合生成异常图像,并使用分割引导的对抗性学习方法使缺陷更加逼真。

3.3 迁移学习

在缺乏大量训练样本的情况下,迁移学习也是

缓解少样本缺陷样本训练导致模型过拟合的关键技术。同时,迁移学习可以节省样本数据获取和标注所需的大量时间与人力成本,也可大幅减少模型训练和调试消耗的时间和计算机资源。

通过迁移学习的方式,使用预训练权值代替随机初始化权值训练新的模型,在预训练的基础上使用现有样本对模型的权值进行修改,提高学习效率的同时也可以提高现有数据的利用率,不需要从零开始训练模型和大量的训练样本。迁移学习可以加快收敛速度,并有助于提高网络的泛化能力,在缺乏大量训练样本的情况下获得好的训练效果。

Lu 等人(2020)提出一种基于迁移学习和集成学习的 CNN 模型,在有限的训练数据集下提高了缺陷检测的精度。范旭辉(2022)针对液晶屏面板的起泡、碎屏和划痕缺陷,将在公开数据集 DAGM2007 上训练得到的权重作为预训练权重应用到改进的 Mask R-CNN 和 YOLOv5 (you only look once version 5) 模型中,加快了模型的收敛速度,并获得了较高的检测准确率。Yang 等人(2018b)提出一种在线连续分类和迁移学习的方法用于 Mura 缺陷的在线训练和分类。它结合了深度卷积特征提取和序列极限学习机分类器,采用特征转移和在线顺序分类策略,大大减少了计算资源和时间。此外,杜彦东等人(2023)为提升模型在有限标注样本情形下的跨域图像分类能力,融合元学习与迁移学习模型进行分类预测。

3.4 监督学习

基于监督学习的深度学习检测方法是在大样本的前提下进行的,随着液晶屏/OLED 屏缺陷数据集不断扩增,此时的缺陷检测方法基于监督学习。目前通用的目标检测算法可以分为两阶段目标检测算法和单阶段目标检测算法。两阶段目标检测算法包获取候选框以及候选框分类和修正两个阶段,代表算法有 R-CNN、Fast R-CNN 和 Faster R-CNN 等。而单阶段目标检测算法通过回归不断优化网络模型的参数,使类别和位置得到准确的判断,典型的算法有 YOLO 系列算法、SSD (single shot multibox detector) (Liu 等,2016)等。基于深度学习的目标分割算法可以分为语义分割和实例分割,语义分割的代表算法有 FCN (fully convolutional network) (Shelhamer 等,2017)、U-Net (Ronneberger 等,2015)等,实例分割的代表算法有 Mask R-CNN。两阶段与单阶段目标检测算法的流程如图 8 所示。




图8 目标检测算法流程图

Fig. 8 Object detection algorithm flow

((a) two-stage; (b) one-stage)

一些学者对现有模型进行改进以提高检测精度。Zhu 等人(2022)建立起多背景图像、多角度的数据集,使用 YOLOv3 建立组合检测框架以提高 LCD 模块级缺陷检测的精度。Chen 等人(2022)在 YOLOv4-tiny 网络模型上添加 SPP (spatial pyramid pooling) 模块和 SE (squeeze-and-excitation module) 模块进行特征融合,有效改善了缺陷漏检问题。彭大芹等人(2021)将候选框网络 (region proposal network, RPN) 与全卷积网络结合,实现各种尺度缺陷的精准分割。

目前,基于监督学习的液晶屏/OLED 屏缺陷检测存在以下难点:1)纹理背景的干扰以及缺陷尺寸差别较大且形状不规则;2)样本不均衡的问题,这会导致模型的收敛速度变慢和检测精度的下降。Lei 等人(2018)针对 Mura 缺陷尺度差别较大、形状不规则的特点,提出了一种基于合并和分割策略的缺陷检测网络 (defect detection network with merging and splitting strategies, MSDDN) 来处理缺陷图像 Mura 缺陷的多种大小和形状变化,大幅提高了检测准确率。宋开友(2021)针对 Mura 缺陷多尺度变化及正负样本不均衡的特点,融合不同尺度的特征以提高模型对不同尺度缺陷的表达能力,引入注意力机制缓解正负样本不均衡问题。Lin 等人(2022)提出一种基于通道注意力的深度分类网络 (deep channel attention-based classification network, DCANet) 进行不同尺度缺陷特征提取,同时提出一种基于 CNN 的对抗训练算法,使用少量样本仍可以显著提高 Mura 缺陷检测的性能,满足工业检测需求,它的检测效果图如图 9 所示。

表 10 对本节讨论的监督学习方法进行检测性




图9 液晶屏 Mura 缺陷检测结果图(Lin 等,2022)
Fig. 9 LCD Mura defect detection results(Lin et al. ,2022)

能描述与效率比较,给出在自建数据集上,相比于原网络模型或通用缺陷检测模型的检测效果。

3.5 小结

本节综述了不同产线阶段基于无监督学习和监督学习的液晶屏/OLED 屏表面缺陷检测方法,并介绍了样本生成方法以及迁移学习。基于无监督学习的方法无需大量标注缺陷样本,其关键是抑制缺陷区域的重构,重构出无缺陷的纹理背景图像。基于监督学习的方法可以得到更好的检测效果,但是需要大量标注缺陷样本,同时仍存在样本不均衡的问题,缺陷的尺寸不一和背景干扰需要引入注意力机制等方法进行克服。表 11 对现有的几类基于深度

表 10 监督学习方法检测性能和效率比较
Table 10 Comparison of performance and efficiency of supervised learning methods

方法	设备	检测图像 /像素	帧速率 /(帧/s)	检测性能描述或比较
Zhu 等人(2022)	NVIDIA Tesla M60	416 × 416	–	搭建的 AOI 系统比人工快 2 倍,召回率提高 2.08%
Chen 等人(2022)	AMD Ryzen 54600H with Radeon Graphics 3 GHz, 16 GB 内存, NVIDIA GeForce GTX 1650 GPU, 4 GB 显存	416 × 416	63.84	mAP 为 99.72%,相比于原 YOLOv4-tiny 模型提高 0.99%,并且高于 YOLOv5、YOLOv4、SSD 等单阶段模型
彭大芹等人(2021)	Intel Core i7-7700HQ, 16 GB 内存, GPU Nvidia 1080	–	7	候选框置信度阈值为 0.8 时,最大 mAP 为 63.8%,相较于未使用 RPN 的 DeepLab v3 提升 3.9%
Lei 等人(2018)	GPU	1 000 × 600	35	mAP 为 90.36%,相较于 AlexNet 提升 14.34%
Lin 等人(2022)	Intel Xeon Gol 处理器, 512 GB 内存, 32 GB 显存 NVIDIA Tesla V100 GPU	416 × 1 024	–	mAP 为 98.37%,相较于 Lei 等人(2018)方法提升 1.55%
宋开友(2021)	Intel Xeon E5-2600 v3 处理器, 64 GB 内存, 2 块 Nvidia Titan Xp GPU	–	–	F1-measure 值为 0.896,相较于 YOLO、SSD 和 Faster RCNN 提高 0.198、0.125 和 0.089; TDR 为 94.5%,相较于 YOLO、SSD 和 Faster RCNN 提高 20.6%、10.0% 和 7.3%

注:“–”表示该项内容为空。

表 11 用于缺陷检测的深度学习模型比较
Table 11 Comparison of deep learning models for defect detection

分类	类别	模型举例	优点	局限性
监督学习	目标分类网络	基于 CNN 的分类器	仅需对整幅图像进行标注,训练和评估所需时间少	需要大量无缺陷和带有缺陷的样本;需要人工进行标注;目标分类无法对缺陷进行定位;需要提高模型对不同尺度缺陷的表达能力,解决样本不均衡问题
	目标检测网络	YOLO、Faster R-CNN 等	YOLO 的检测速度非常快;只需要框型标注	
	目标分割网络	U-Net、FCN、Mask R-CNN 等	训练和评估快,可以实现很好的缺陷像素级分割与定位	
无监督学习	基于 GAN 的异常检测	AnoGAN、OCGAN 等	仅需无缺陷样本即可进行训练,无需像素级的标注	缺乏对缺陷的定位,需要精确抑制缺陷区域的重构
	基于 AE 的异常检测	MSCDAE、MS-FCAE 等		

学习的缺陷检测方法进行了对比。

4 数据集和性能评价指标

4.1 数据集

目前,并没有基于液晶屏/OLED屏缺陷的公开数据集,学者们自建数据集进行模型训练与测试,本文对自建数据集进行总结,如表12所示。基于纹理背景缺陷检测的通用纹理表面缺陷数据集,可用于算法可行性与通用性验证、算法对比,同时也可用于迁移学习预训练权重的训练等,总结的数据集如表13所示。

4.2 性能评价指标

准确率(accuracy)衡量正确分类的样本数占有样本数的比例。召回率(recall, R)衡量模型检测正确性的能力。精确率(precision, P)衡量模型预测的准确性。F1-measure是精确率和召回率的调和平均值(周志华,2016)。

以精确率为纵轴、召回率为横轴作图,就可以得到P-R曲线,P-R曲线直观地显示出模型在样本总体上的查全率。平均精度(average precision, AP)的一般定义是P-R曲线下方的面积。平均精度均值(mean average precision, mAP)(周志华,2016)是C个不同缺陷AP值的平均值,它反映了缺陷检测的

表 12 自建液晶屏/OLED屏表面缺陷数据集
Table 12 Self-built LCD/OLED surface defect datasets

自建数据集	图像数量/幅	图像尺寸/像素	包含缺陷类别	是否标注
Song等人(2021b)	644	128×128	无缺陷样本544幅、条纹Mura200幅、线形Mura84幅	否
刘强(2020)	2000	512×512	无缺陷样本,点缺陷、线缺陷、Mura缺陷和压伤等缺陷占5%	否
Mei等人(2017)				
Mei等人(2018)	14491	64×64	点Mura6418幅、线Mura1876幅、区域Mura6197幅	否
Yang等人(2019)				
代朝东等人(2021)	2556	256×256	无缺陷样本3000幅、点缺陷831幅、线缺陷757幅、Mura缺陷968幅	否
Yang等人(2021)	2922	256×256	无缺陷样本2754幅、缺陷样本168幅	否
Song等人(2021a)	6088	256×256	无缺陷样本2538幅、缺陷样本3550幅	否
Zhu等人(2022)	3500	416×416	包含点缺陷、线缺陷、Mura缺陷共53种缺陷类型	是
Chen等人(2022)	700	416×416	包含点Mura和区域Mura	是
彭大芹等人(2021)	10000	—	Mura缺陷3100幅、划痕2520幅、白印1260幅、暗斑1260幅、其他1860幅	是
Lei等人(2018)	52970	128×128	27250无缺陷样本,25720缺陷样本	是
宋开友(2021)	30050	300×300	30050个Mura缺陷样本	是
Lin等人(2022)	8105	416×1024	6847个浅Mura缺陷,1258个明显Mura缺陷	是

表 13 通用纹理表面缺陷数据集
Table 13 Universal texture surface defect datasets

数据集	类别	是否包含缺陷样本	下载地址
DAGM2007(Wieler等,2007)	针对纹理背景上的杂项缺陷,共10类	是,弱标签标注	https://hci.iwr.uni-heidelberg.de/content/weakly-supervised-learning-industrial-optical-inspection
MVTec AD(Bergmann等,2019)	纹理背景上的杂项缺陷,共5类	是,像素级标注	https://www.mvtec.com/company/research/datasets/mvtec-ad
KTH-TIPS2b(Mallikarjuna等,2006)	纹理图像数据集,共11类	否	https://www.csc.kth.se/evap/databases/kth-tips/index.html
FMD(Sharan等,2014)	纹理图像数据集,共10类	否	http://people.csail.mit.edu/lavanya/fmd.html
DTD(Cimpoi等,2014)	纹理图像数据集,共47类	否	https://www.robots.ox.ac.uk/~vgg/data/dtd/

准确性。

ROC(receiver operating characteristic)曲线以真正例率(true positive rate, TPR)为纵轴,以假正例率(false positive rate, FPR)为横轴作图,以衡量学习器的泛化性能(周志华,2016)。

AUC(area under the curve of ROC)表示ROC曲线下各部分的面积求和,AUC越大,分类器分类效果越好。

混淆矩阵(confusion matrix)将分类结果的精度进行可视化,每行代表真实类别,每列表示预测类别,通过混淆矩阵可以可视化地观察到错误分类的情况。

检出率TDR(true detection rate)(宋开友,2021)计算为

$$f_{\text{TDR}} = \frac{N_{\text{td}}}{N_{\text{total}}} \quad (14)$$

式中, N_{total} 为测试集中所有缺陷的数量,当检测到的缺陷区域与真实缺陷区域的交并比大于阈值时,缺陷被视为正确检出, N_{td} 为正确检测出的缺陷数量,其计算式为

$$N_{\text{td}} = \sum_{i=1}^{N_{\text{total}}} \mathbb{I} \left(\frac{TP_i}{TP_i + FP_i + FN_i} > T_{\text{thr}} \right) \quad (15)$$

式中, $\mathbb{I}(\cdot)$ 是0-1指示函数, T_{thr} 是预设的阈值,一般取0.5。

过检率FDR(false detection rate)(宋开友,2021)用于评估算法在无缺陷样本上的误检情况,计算为

$$f_{\text{FDR}} = \frac{N_{\text{fd}}}{N_p} \quad (16)$$

式中, N_p 为测试集无缺陷样本数量, N_{fd} 为测试集误检的无缺陷样本数量。

5 问题与展望

5.1 主要问题

1)液晶屏/OLED屏数据集有限。其一,样本稀缺与样本不均衡。在工业生产中很难采集到大量液晶屏/OLED屏的缺陷样本,由于一些缺陷十分稀缺,数据集中缺陷的类型不完善,从而导致样本不均衡的问题。其二,样本标注问题。Mura缺陷需要专业质检人员进行标注,这将耗费大量的人力物力。

2)小尺寸缺陷漏检问题。液晶屏/OLED屏缺陷种类多,具有大范围尺度变化的特点,使用卷积神经网络

进行特征提取时,随着层数的增多,小目标缺陷特征逐渐丢失,导致小尺寸液晶屏/OLED屏缺陷漏检,如何使用注意力机制等特征融合手段对模型进行改进仍是待解决的问题。同时,现代液晶屏和OLED屏通常具有极高的分辨率和像素密度,使得检测微小缺陷变得更加困难。

3)Mura缺陷特性造成的检测困难。Mura缺陷具有低对比度、边缘模糊的特点,人眼有时也难以分辨,这也使传统的阈值分割和边缘检测方法不能直接应用于Mura缺陷检测。如何提高Mura缺陷的对比度并进行准确分割是Mura缺陷检测的关键所在。

4)实时性问题。在工业生产中,需要保证液晶屏/OLED屏缺陷检测的实时性以提高检测的效率。使用高分辨率设备采集液晶屏/OLED屏检测图像时,虽然高分辨率图像可以提高检测精度,但是计算参数量变大,处理时间变长,实时性下降。

5)复杂背景问题。由于液晶屏/OLED屏内部结构的原因,获得的待检测图像具有亮度不均匀和纹理背景的特点,消除背景干扰后增强疑似的缺陷区域可以有效提高检测精度,但是在处理小目标缺陷的时候准确度较低。

5.2 展望

1)缺陷样本生成技术。目前并没有公开的液晶屏/OLED屏表面缺陷数据集,且数据集存在样本不均衡的问题,如何利用GAN生成更接近真实缺陷的样本,以及如何节省标记样本所需的大量人力物力是值得思考的问题。

2)模型融合。本文的液晶屏/OLED屏缺陷检测方法针对特定几种缺陷进行检测,且很多方法只检测缺陷的有无,而不进行进一步的缺陷量化与分类,利用多模型或多阶段搭建完善的系统,每个模型或阶段专门用于检测特定类型的缺陷,对每种类型的缺陷进行分类和检测,更有利于工业部署。

3)可迁移深度学习。当产线中投入新类型的液晶屏/OLED屏产品时,需要再次采集样本训练以提高检测准确率,模型无法快速地应用于新类型的液晶屏/OLED屏。因此,研究可迁移的算法模型或应用元学习具有重要意义。

4)深度学习模型加速技术。本文提及的基于深度学习的无监督与监督学习,都需要对模型进行训练,这些模型参数量巨大,训练时间长,并且对计算机的算力有需求。构建轻量化模型或应用知识蒸馏

可以减少模型训练时间,降低计算成本,提高处理速度。

5)应用Transformer模型。Transformer在自然语言处理领域取得了巨大的成功,在视觉领域,基于Transformer的目标检测逐渐成为热点,但是目前通用的模型存在收敛性差、不适用于检测小目标缺陷的不足,如何改进模型实现液晶屏/OLED屏表面缺陷精确检测值得思考。

6)曲面屏缺陷检测技术。如今曲面屏、可折叠屏和柔性屏广泛应用于手机屏幕与显示器,研究基于三维视觉的曲面屏的缺陷检测具有十分重要的现实意义。

6 结 语

随着机器视觉技术的飞速发展,基于机器视觉的缺陷检测方法逐渐崭露头角,其独特的优势包括出色的检测速度、低成本、高精度以及非接触性,这些特性提高了生产和检测效率,为制造商创造了更大的利润空间,是当今的研究热点。然而,液晶屏/OLED屏自身的特性,如不均匀光照和纹理背景等,使得缺陷的分割和特征提取变得更加复杂和具有挑战性。本文深入探讨了基于视觉的液晶屏/OLED屏表面缺陷检测方法,旨在为这一领域的研究和应用提供全面的视角。

首先介绍了基于图像处理的背景消除或抑制法和基于特征提取的缺陷检测方法,它们设计简单,不需要大量缺陷数据样本,但缺乏通用性,易受环境因素影响,且在处理复杂的图像背景和大规模数据时速度较慢,实时性较差。随着深度学习技术的迅猛发展,研究人员开始积极探索这一领域,利用深度学习方法来实现更快速、更准确的液晶屏/OLED屏缺陷检测。深度学习的优势在于其出色的特征提取和模式识别能力,使其能够在复杂的环境下更好地区分缺陷和正常结构。但基于深度学习的液晶屏/OLED屏仍面临着数据集缺乏这一显著问题,同时,数据集的收集和标记成本较高,这限制了深度学习方法的广泛应用。为了解决这一问题,研究人员正在尝试利用迁移学习和无监督学习等方法,以在缺乏大规模标记数据的情况下进行训练,或者利用生成方法生成缺陷样本,这些方法有望为液晶屏/OLED屏缺陷检测的进一步研究提供新的可能性。

通过以上的总结和分析,本文旨在为液晶屏/OLED屏缺陷检测方法的研究和应用提供有价值的参考。随着机器视觉和深度学习技术的不断发展,有理由相信,液晶屏/OLED屏缺陷检测将迎来更多的创新和突破,推动这一领域不断前进,为制造业和技术发展带来更多可能性。

参考文献(References)

- Aiger D and Talbot H. 2010. The phase only transform for unsupervised surface defect detection//Proceedings of 2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. San Francisco, USA: IEEE: 295-302 [DOI: 10.1109/CVPR.2010.5540198]
- Badrinarayanan V, Kendall A and Cipolla R. 2017. SegNet: a deep convolutional encoder-decoder architecture for image segmentation. IEEE Transactions on Pattern Analysis and Machine Intelligence, 39(12): 2481-2495 [DOI: 10.1109/TPAMI.2016.2644615]
- Bergmann P, Fauser M, Sattlegger D and Steger C. 2019. MVTec AD: a comprehensive real-world dataset for unsupervised anomaly detection//Proceedings of 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, USA: IEEE: 9584-9592 [DOI: 10.1109/CVPR.2019.00982]
- Bhalla K and Huang Y P. 2021. An adaptive thresholding based method to locate and segment defects on LCD panels//Proceedings of 2021 International Conference on System Science and Engineering (ICSSE). Ho Chi Minh City, Vietnam: IEEE: 328-333 [DOI: 10.1109/ICSSE52999.2021.9538470]
- Bi X and Ding H. 2010. Machine vision inspection method of Mura defect for TFT-LCD. Journal of Mechanical Engineering, 46(12): 13-19 (毕昕, 丁汉. 2010. TFT-LCD Mura缺陷机器视觉检测方法. 机械工程学报, 46(12): 13-19) [DOI: 10.3901/JME.2010.12.013]
- Bi X, Zhuang C G and Ding H. 2009. A new Mura defect inspection way for TFT-LCD using level set method. IEEE Signal Processing Letters, 16(4): 311-314 [DOI: 10.1109/LSP.2009.2014113]
- Cen Y G, Zhao R Z, Cen L H, Cui L H, Miao Z J and Wei Z. 2015. Defect inspection for TFT-LCD images based on the low-rank matrix reconstruction. Neurocomputing, 149: 1206-1215 [DOI: 10.1016/j.neucom.2014.09.007]
- Chen F C, Fang L T, Lee L, Wen C H, Cheng S Y and Wang S J. 2005. LOG-filter-based inspection of cluster Mura and vertical-band Mura on liquid crystal displays//Proceedings Volume 5679, Machine Vision Applications in Industrial Inspection XIII. San Jose, USA: SPIE: 257-265 [DOI: 10.1117/12.586688]
- Chen L C and Kuo C C. 2008. Automatic TFT-LCD Mura defect inspection using discrete cosine transform-based background filtering and

- 'just noticeable difference' quantification strategies. *Measurement Science and Technology*, 19(1): #015507 [DOI: 10.1088/0957-0233/19/1/015507]
- Chen M F, Chen P, Wang S, Cui Y, Zhang Y X and Chen S L. 2022. TFT-LCD Mura defect visual inspection method in multiple backgrounds. *Journal of the Society for Information Display*, 30(11): 818-831 [DOI: 10.1002/jsid.1171]
- Chen S L and Chou S T. 2008. TFT-LCD Mura defect detection using wavelet and cosine transforms. *Journal of Advanced Mechanical Design, Systems, and Manufacturing*, 2(3): 441-453 [DOI: 10.1299/jamdsm.2.441]
- Cimpoi M, Maji S, Kokkinos I, Mohamed S and Vedaldi A. 2014. Describing textures in the wild//*Proceedings of 2014 IEEE Conference on Computer Vision and Pattern Recognition*. Columbus, USA: IEEE: 3606-3613 [DOI: 10.1109/CVPR.2014.461]
- Dai C D, Xu G L, Mao J, Gu T and Luo J Y. 2021. Cell phone screen defect segmentation based on unsupervised network. *Laser and Optoelectronics Progress*, 58(20): #2015003 (代朝东, 许国良, 毛骄, 顾桐, 雒江涛. 2021. 基于无监督网络的手机屏幕缺陷分割方法. *激光与光电子学进展*, 58(20): #2015003) [DOI: 10.3788/LOP202158.2015003]
- Du Y D, Feng L, Tao P, Gong X and Wang J. 2023. Meta-transfer learning in cross-domain image classification with few-shot learning. *Journal of Image and Graphics*, 28(9): 2899-2912 (杜彦东, 冯林, 陶鹏, 龚勋, 王俊. 2023. 元迁移学习在少样本跨域图像分类中的研究. *中国图象图形学报*, 28(9): 2899-2912) [DOI: 10.11834/jig.220664]
- Fan X H. 2022. Research on Surface Defect Detection Method of LCD Screen Based on Deep Learning. Anqing: Anqing Normal University (范旭辉. 2022. 基于深度学习的液晶屏表面缺陷检测方法研究. 安庆: 安庆师范大学) [DOI: 10.27761/d.cnki.gaqsf.2022.000254]
- Fang L T, Chen H C, Yin I C, Wang S J, Wen C H and Kuo C H. 2006. Automatic Mura detection system for liquid crystal display panels//*Proceedings Volume 6070, Machine Vision Applications in Industrial Inspection XIV*. San Jose, USA: SPIE: 143-152 [DOI: 10.1117/12.650686]
- Gan Y Z and Zhao Q F. 2013. An effective defect inspection method for LCD using active contour model. *IEEE Transactions on Instrumentation and Measurement*, 62(9): 2438-2445 [DOI: 10.1109/TIM.2013.2258242]
- Goodfellow I, Pouget-Abadie J, Mirza M, Xu B, Warde-Farley D, Ozair S, Courville A and Bengio Y. 2020. Generative adversarial networks. *Communications of the ACM*, 63(11): 139-144 [DOI: 10.1145/3422622]
- He K M, Zhang X Y, Ren S Q and Sun J. 2016. Deep residual learning for image recognition//*Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Las Vegas, USA: IEEE: 770-778 [DOI: 10.1109/CVPR.2016.90]
- He Z Y and Sun L N. 2015. Surface defect detection method for glass substrate using improved Otsu segmentation. *Applied Optics*, 54(33): 9823-9830 [DOI: 10.1364/AO.54.009823]
- Hecht S. 1924. The visual discrimination of intensity and the Weber-Fechner law. *The Journal of General Physiology*, 7(2): 235-267 [DOI: 10.1085/jgp.7.2.235]
- Hinton G E and Salakhutdinov R R. 2006. Reducing the dimensionality of data with neural networks. *Science*, 313(5786): 504-507 [DOI: 10.1126/science.1127647]
- Huang G, Liu Z, van der Maaten L and Weinberger K Q. 2017. Densely connected convolutional networks//*Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition*. Honolulu, USA: IEEE: 2261-2269 [DOI: 10.1109/CVPR.2017.243]
- Jazi A Y, Liu J J and Lee H. 2012. Automatic inspection of TFT-LCD glass substrates using optimized support vector machines. *IFAC Proceedings Volumes*, 45(15): 325-330 [DOI: 10.3182/20120710-4-SG-2026.00054]
- Jian C X. 2015. Review of TFT-LCD surface defect detection methods. *Video Engineering*, 39(9): 146-152 (简川霞. 2015. TFT-LCD表面缺陷检测方法综述. *电视技术*, 39(9): 146-152) [DOI: 10.16280/j.videoe.2015.09.034]
- Jian C X, Wang H M, Xu J J, Su L H and Wang T P. 2021. Automatic surface defect detection for OLED display. *Packaging Engineering*, 42(13): 280-287 (简川霞, 王华明, 徐进军, 苏林海, 王太平. 2021. OLED显示屏表面缺陷自动检测方法. *包装工程*, 42(13): 280-287) [DOI: 10.19554/j.cnki.1001-3563.2021.13.039]
- Jin S Q, Ji C, Yan C C and Xing J Y. 2018. TFT-LCD Mura defect detection using DCT and the dual- γ piecewise exponential transform. *Precision Engineering*, 54: 371-378 [DOI: 10.1016/j.precisioneng.2018.07.006]
- Kang S B, Lee J H, Song K Y and Pak H J. 2009. Automatic defect classification of TFT-LCD panels using machine learning//*Proceedings of 2009 IEEE International Symposium on Industrial Electronics*. Seoul, Korea (South): IEEE: 2175-2177 [DOI: 10.1109/ISIE.2009.5213760]
- Krizhevsky A, Sutskever I and Hinton G. 2017. ImageNet classification with deep convolutional neural networks. *Communications of the ACM*, 60(6): 84-90 [DOI: 10.1145/3065386]
- Lee J Y and Yoo S I. 2004. Automatic detection of region-Mura defect in TFT-LCD. *IEICE Transactions on Information and Systems*, 87(10): 2371-2378
- Lee M C H, Petersen K, Pawlowski N, Glocker B and Schaap M. 2019. TETRIS: template Transformer networks for image segmentation with shape priors. *IEEE Transactions on Medical Imaging*, 38(11): 2596-2606 [DOI: 10.1109/TMI.2019.2905990]
- Lei J, Gao X, Feng Z L, Qiu H M and Song M L. 2018. Scale insensi-

- tive and focus driven mobile screen defect detection in industry. *Neurocomputing*, 294: 72-81 [DOI: 10.1016/j.neucom.2018.03.013]
- Li C M, Kao C Y, Gore J C and Ding Z H. 2007. Implicit active contours driven by local binary fitting energy//*Proceedings of 2007 IEEE Conference on Computer Vision and Pattern Recognition*. Minneapolis, USA: IEEE: #383014 [DOI: 10.1109/CVPR.2007.383014]
- Li C M, Kao C Y, Gore J C and Ding Z H. 2008. Minimization of region scalable fitting energy for image segmentation. *IEEE Transactions on Image Processing*, 17 (10): 1940-1949 [DOI: 10.1109/TIP.2008.2002304]
- Li K, Li H, Liu Y J, Liang P and Lu X P. 2014. Background suppression of LCD Mura defect using B-spline surface fitting. *Opto-Electronic Engineering*, 41(2): 33-39 (李坤, 李辉, 刘云杰, 梁平, 卢小鹏. 2014. LCD Mura缺陷的B样条曲面拟合背景抑制. *光电工程*, 41(2): 33-39) [DOI: 10.3969/j.issn.1003-501X.2014.02.006]
- Li W C and Tsai D M. 2011. Defect inspection in low-contrast LCD images using Hough transform-based nonstationary line detection. *IEEE Transactions on Industrial Informatics*, 7 (1): 136-147 [DOI: 10.1109/TII.2009.2034844]
- Liang J F, Li T, Yang J Q, Li Y N, Fang Z W and Yang F. 2023. Video anomaly detection by fusing self-attention and autoencoder. *Journal of Image and Graphics*, 28(4): 1029-1040 (梁家菲, 李婷, 杨佳琪, 李亚楠, 方智文, 杨丰. 2023. 融合自注意力和自编码器的视频异常检测. *中国图象图形学报*, 28(4): 1029-1040) [DOI: 10.11834/jig.211147]
- Lin G M, Kong L F, Liu T J, Qiu L D and Chen X Y. 2022. An antagonistic training algorithm for TFT-LCD module Mura defect detection. *Signal Processing: Image Communication*, 107: #116791 [DOI: 10.1016/j.image.2022.116791]
- Lin T Y, Goyal P, Girshick R, He K M and Dollár P. 2020. Focal loss for dense object detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42 (2): 318-327 [DOI: 10.1109/TPAMI.2018.2858826]
- Liu J Y, Wu H, Liu Y L and Wang J C. 2022. Automatic generation and detection method of LCD samples based on deep learning//*Proceedings of the 5th World Conference on Mechanical Engineering and Intelligent Manufacturing (WCMEIM)*. Ma' anshan, China: IEEE: 724-730 [DOI: 10.1109/WCMEIM56910.2022.10021421]
- Liu Q. 2020. Research on Visual Inspection Technology for Display Defects of New Array Panel. Harbin: Harbin Institute of Technology (刘强. 2020. 新型阵列屏体的显示缺陷视觉检测技术研究. 哈尔滨: 哈尔滨工业大学) [DOI: 10.27061/d.cnki.ghgdu.2020.006330]
- Liu W, Anguelov D, Erhan D, Szegedy C, Reed S, Fu C Y and Berg A C. 2016. SSD: single shot MultiBox detector//*Proceedings of the 14th European Conference on Computer Vision*. Amsterdam, The Netherlands: Springer: 21-37 [DOI: 10.1007/978-3-319-46448-0_2]
- Liu Y H and Chen Y J. 2011. Automatic defect detection for TFT-LCD array process using quasiconformal kernel support vector data description. *International Journal of Molecular Sciences*, 12 (9): 5762-5781 [DOI: 10.3390/ijms12095762]
- Liu Y H, Huang Y K and Lee M J. 2008. Automatic inline defect detection for a thin film transistor—liquid crystal display array process using locally linear embedding and support vector data description. *Measurement Science and Technology*, 19(9): #095501 [DOI: 10.1088/0957-0233/19/9/095501]
- Liu Y H, Lin S H, Hsueh Y L and Lee M J. 2009a. Automatic target defect identification for TFT-LCD array process inspection using kernel FCM-based fuzzy SVDD ensemble. *Expert Systems with Applications*, 36 (2): 1978-1998 [DOI: 10.1016/j.eswa.2007.12.015]
- Liu Y H, Liu Y C and Chen Y Z. 2011. High-speed inline defect detection for TFT-LCD array process using a novel support vector data description. *Expert Systems with Applications*, 38(5): 6222-6231 [DOI: 10.1016/j.eswa.2010.11.046]
- Liu Y H, Wang C K, Ting Y, Lin W Z, Kang Z H, Chen C S and Hwang J S. 2009b. In-TFT-array-process micro defect inspection using nonlinear principal component analysis. *International Journal of Molecular Sciences*, 10 (10): 4498-4514 [DOI: 10.3390/ijms10104498]
- Lu C J and Tsai D M. 2005. Automatic defect inspection for LCDs using singular value decomposition. *The International Journal of Advanced Manufacturing Technology*, 25 (1/2): 53-61 [DOI: 10.1007/s00170-003-1832-6]
- Lu C J and Tsai D M. 2008. Independent component analysis-based defect detection in patterned liquid crystal display surfaces. *Image and Vision Computing*, 26(7): 955-970 [DOI: 10.1016/j.imavis.2007.10.007]
- Lu H P and Su C T. 2021. CNNs combined with a conditional GAN for Mura defect classification in TFT-LCDs. *IEEE Transactions on Semiconductor Manufacturing*, 34(1): 25-33 [DOI: 10.1109/TSM.2020.3048631]
- Lu X P. 2014. Study on the Methods of Machine Vision Inspection for the Mura Defect of TFT-LCD. Chengdu: University of Electronic Science and Technology of China (卢小鹏. 2014. TFT-LCD Mura缺陷机器视觉检测方法研究. 成都: 电子科技大学)
- Lu X P, Li H, Liu Y J, Liang P and Li K. 2014. Algorithm for fast TFT-LCD Mura defect image segmentation based on Chan-Vese model. *Chinese Journal of Liquid Crystals and Displays*, 29(1): 146-151 (卢小鹏, 李辉, 刘云杰, 梁平, 李坤. 2014. 基于 Chan-Vese 模型的 TFT-LCD Mura 缺陷快速分割算法. *液晶与显示*, 29(1): 146-151) [DOI: 10.3788/YJYXS20142901.0146]

- Lu Y, Ma L and Jiang H Q. 2020. A light CNN model for defect detection of LCD//Frontier Computing (FC 2019). Singapore, Singapore: Springer: 10-19 [DOI: 10.1007/978-981-15-3250-4_2]
- Mallikarjuna P, Targhi A T, Fritz M, Hayman E, Caputo B and Eklundh J O. 2006. The KTH-TIPS2 database. Stockholm, Sweden: Computational Vision and Active Perception Laboratory, School of Computer Science and Communication
- Mei S. 2017. Research on TFT-LCD Mura Defect Recognition Based on Deep Learning. Wuhan: Huazhong University of Science and Technology (梅爽. 2017. 基于深度学习的液晶屏 Mura 缺陷图像识别算法研究. 武汉: 华中科技大学)
- Mei S, Yang H and Yin Z P. 2017. Unsupervised-learning-based feature-level fusion method for Mura defect recognition. IEEE Transactions on Semiconductor Manufacturing, 30 (1): 105-113 [DOI: 10.1109/TSM.2017.2648856]
- Mei S, Yang H and Yin Z P. 2018. An unsupervised-learning-based approach for automated defect inspection on textured surfaces. IEEE Transactions on Instrumentation and Measurement, 67 (6): 1266-1277 [DOI: 10.1109/TIM.2018.2795178]
- Ming W Y, Zhang S F, Liu X W, Liu K, Yuan J, Xie Z B, Sun P Y and Guo X D. 2021. Survey of Mura defect detection in liquid crystal displays based on machine vision. Crystals, 11 (12): #1444 [DOI: 10.3390/cryst11121444]
- Nakano H and Mori Y. 2005. Measurement method for low-contrast non-uniformity in liquid crystal displays by using multi-wavelet analysis//Proceedings Volume 5880, Optical Diagnostics. San Diego, USA: SPIE: 313-318 [DOI: 10.1117/12.616232]
- Oh J H, Yun B J and Park K H. 2007. The defect detection using human visual system and wavelet transform in TFT-LCD image//2007 Frontiers in the Convergence of Bioscience and Information Technologies. Jeju, Korea (South): IEEE: 498-503 [DOI: 10.1109/FBIT.2007.49]
- Ouyang T. 2018. Research and Implementation of Defect Detection Algorithm for OLED Display. Shanghai: Shanghai Jiao Tong University (欧阳韬. 2018. OLED 显示屏缺陷检测算法的研究与实现. 上海: 上海交通大学)
- Peng D Q, Liu H and Xu G L. 2021. Object segmentation algorithm modified by candidate box for fully convolution network. Journal of Chongqing University of Posts and Telecommunications (Natural Science Edition), 33 (1): 135-143 (彭大芹, 刘恒, 许国良. 2021. 使用候选框进行全卷积网络修正的目标分割算法. 重庆邮电大学学报(自然科学版), 33 (1): 135-143) [DOI: 10.3979/j.issn.1673-825X.201903210099]
- Pratt W K, Sawkar S S and O'Reilly K. 1998. Automatic blemish detection in liquid crystal flat panel displays//Proceedings Volume 3306, Machine Vision Applications in Industrial Inspection VI. San Jose, USA: SPIE: 2-13 [DOI: 10.1117/12.301232]
- Qian J D, Chen B, Qian J Y, Zhao H J and Chen G. 2018. Machine vision based inspection method of Mura defect for LCD. Computer Science, 45 (6): 296-300, 313 (钱基德, 陈斌, 钱基业, 赵恒军, 陈刚. 2018. 基于机器视觉的液晶屏 Mura 缺陷检测方法. 计算机科学, 45 (6): 296-300, 313) [DOI: 10.11896/j.issn.1002-137X.2018.06.052]
- Redmon J, Divvala S, Girshick R and Farhadi A. 2016. You only look once: unified, real-time object detection//Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, USA: IEEE: 779-788 [DOI: 10.1109/CVPR.2016.91]
- Ren S Q, He K M, Girshick R and Sun J. 2017. Faster R-CNN: towards real-time object detection with region proposal networks. IEEE Transactions on Pattern Analysis and Machine Intelligence, 39 (6): 1137-1149 [DOI: 10.1109/TPAMI.2016.2577031]
- Ronneberger O, Fischer P and Brox T. 2015. U-Net: convolutional networks for biomedical image segmentation//Proceedings of the 18th Medical Image Computing and Computer-Assisted Intervention. Munich, Germany: Springer: 234-241 [DOI: 10.1007/978-3-319-24574-4_28]
- SEMI. 2002. SEMI D31-1102: Definition of measurement index (Semu) for luminance Mura in FPD image quality inspection//Japan FPD Metrology Committee Meeting Minutes. Yokohama, Japan
- Sharan L, Rosenholtz R and Adelson E H. 2014. Accuracy and speed of material categorization in real-world images. Journal of Vision, 14 (9): #12 [DOI: 10.1167/14.9.12]
- Shelhamer E, Long J and Darrell T. 2017. Fully convolutional networks for semantic segmentation. IEEE Transactions on Pattern Analysis and Machine Intelligence, 39 (4): 640-651 [DOI: 10.1109/TPAMI.2016.2572683]
- Shuai L Y, Chen H X and Wang Z X. 2022. Defect detection of four-color display screen based on color equalization and local dynamic threshold segmentation//Proceedings of AIIICC 2022, the 3rd International Conference on Artificial Intelligence, Information Processing and Cloud Computing. Online: VDE: 1-5
- Song K Y. 2021. Research on Visual Inspection Algorithm of Mura Defects Based on Deep Feature Encoding. Wuhan: Huazhong University of Science and Technology (宋开友. 2021. 基于深度特征编码的 Mura 缺陷视觉检测算法研究. 武汉: 华中科技大学) [DOI: 10.27157/d.cnki.ghzku.2021.006214]
- Song K Y, Yang H and Yin Z P. 2021a. Multi-scale boosting feature encoding network for texture recognition. IEEE Transactions on Circuits and Systems for Video Technology, 31 (11): 4269-4282 [DOI: 10.1109/TCSVT.2021.3051003]
- Song K Y, Yang H and Yin Z P. 2022. Anomaly composition and decomposition network for accurate visual inspection of texture defects. IEEE Transactions on Instrumentation and Measurement, 71: #5017814 [DOI: 10.1109/TIM.2022.3196133]
- Song S B, Yang K C, Wang A N, Zhang S S and Xia M. 2021b. A Mura detection model based on unsupervised adversarial learning. IEEE

- Access, 9: 49920-49928 [DOI: 10.1109/ACCESS.2021.3069466]
- Tan M X and Le Q V. 2019. EfficientNet: rethinking model scaling for convolutional neural networks//Proceedings of the 36th International Conference on Machine Learning. Long Beach, USA: JMLR: 6105-6114 [DOI: 10.48550/arXiv.1905.11946]
- Tan M X, Pang R M and Le Q V. 2020. EfficientDet: scalable and efficient object detection//Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, USA: IEEE: 10778-10787 [DOI: 10.1109/CVPR42600.2020.01079]
- Taniguchi K, Ueta K, Onishi H and Tatsumi S. 2007. A method of Mura intensity quantification using multi-level sliced images//Proceedings Volume 6356, the 8th International Conference on Quality Control by Artificial Vision. Le Creusot, France: SPIE: 124-131 [DOI: 10.1117/12.736735]
- Torres G M, Souza A S, Ferreira D A O, Junior L C S G, Ouchi K Y, Valadao M D M, Silva M O, Cavalcante V L G, Mattos E V C U, Pereira A M C, Cruz C F S, Silva A P, Belem R J S, Costa A S, Evangelista L G C, Junior W C C, Paula R G, Bezerra T B, Junior W S S and Carvalho C B. 2021. Automated Mura defect detection system on LCD displays using random forest classifier//Proceedings of 2021 IEEE International Conference on Consumer Electronics (ICCE). Las Vegas, USA: IEEE: #9427579 [DOI: 10.1109/ICCE50685.2021.9427579]
- Tsai D M, Chuang S T and Tseng Y H. 2007. One-dimensional-based automatic defect inspection of multiple patterned TFT-LCD panels using Fourier image reconstruction. International Journal of Production Research, 45(6): 1297-1321 [DOI: 10.1080/00207540600622464]
- Tsai D M, Fan S K S and Chou Y H. 2021. Auto-annotated deep segmentation for surface defect detection. IEEE Transactions on Instrumentation and Measurement, 70: #5011410 [DOI: 10.1109/TIM.2021.3087826]
- Tsai D M and Hung C Y. 2005. Automatic defect inspection of patterned thin film transistor-liquid crystal display (TFT-LCD) panels using one-dimensional Fourier reconstruction and wavelet decomposition. International Journal of Production Research, 43(21): 4589-4607 [DOI: 10.1080/00207540500140732]
- Tsai D M, Lin P C and Lu C J. 2006. An independent component analysis-based filter design for defect detection in low-contrast surface images. Pattern Recognition, 39(9): 1679-1694 [DOI: 10.1016/j.patcog.2006.03.005]
- Tuyen Le N, Wang J W, Shih M H and Wang C C. 2020. Novel framework for optical film defect detection and classification. IEEE Access, 8: 60964-60978 [DOI: 10.1109/ACCESS.2020.2982250]
- Wang H S and Yang Y Y. 2018. Surface defect inspection of TFT-LCD panels based on improved saliency model. Journal of Electronic Measurement and Instrumentation, 32(7): 29-35 (王宏硕, 杨永跃. 2018. 基于改进显著性模型的TFT-LCD面板缺陷检测. 电子测量与仪器学报, 32(7): 29-35) [DOI: 10.13382/j.jemi.2018.07.005]
- Wang X, Dong R and Li B. 2016. TFT-LCD Mura defect detection based on ICA and multi-channels fusion//Proceedings of the 3rd International Conference on Information Science and Control Engineering (ICISCE). Beijing, China: IEEE: 687-691 [DOI: 10.1109/ICISCE.2016.152]
- Wang Y Y, Hou J, Li M S, Xue T and Xiao X. 2021. Defect detection of LCD based on texture elimination. Electronic Measurement Technology, 44(12): 93-96 (汪永勇, 侯俊, 李梦思, 薛彤, 肖雄. 2021. 基于纹理消除的液晶屏缺陷检测. 电子测量技术, 44(12): 93-96) [DOI: 10.19651/j.cnki.emt.2106557]
- Wieler M, Hahn T and Hamprecht F A. 2007. Weakly supervised learning for industrial optical inspection [EB/OL]. [2023-07-06]. <https://hci.iwr.uni-heidelberg.de/content/weakly-supervised-learning-industrial-optical-inspection>
- Xie E Z, Wang W J, Wang W H, Sun P Z, Xu H, Liang D and Luo P. 2021. Trans2Seg: transparent object segmentation with Transformer [EB/OL]. [2023-07-06]. <https://arxiv.org/pdf/2101.08461v2.pdf>
- Xie R, Li G and Zhang R B. 2016. High quality background modeling of LCD-Mura defect. Journal of Computer Applications, 36(4): 1151-1155, 1162 (谢瑞, 李钢, 张仁斌. 2016. 液晶显示器斑痕缺陷高质量背景建模. 计算机应用, 36(4): 1151-1155) [DOI: 10.11772/j.issn.1001-9081.2016.04.1151]
- Xie X H and Mirmehdi M. 2007. TEXEMS: texture exemplars for defect detection on random textured surfaces. IEEE Transactions on Pattern Analysis and Machine Intelligence, 29(8): 1454-1464 [DOI: 10.1109/TPAMI.2007.1038]
- Yan C C, Jin S Q, Yan Z Z and Hu H B. 2017. TFT-LCD detection algorithm combining weighted template difference image and bilateral filtering. Journal of Electronic Measurement and Instrumentation, 31(9): 1434-1440 (严成宸, 金施群, 闫真真, 胡海兵. 2017. 结合加权模板差图与双边滤波的TFT-LCD检测算法. 电子测量与仪器学报, 31(9): 1434-1440) [DOI: 10.13382/j.jemi.2017.09.013]
- Yang H, Chen Y F, Song K Y and Yin Z P. 2019. Multiscale feature-clustering-based fully convolutional autoencoder for fast accurate visual inspection of texture surface defects. IEEE Transactions on Automation Science and Engineering, 16(3): 1450-1467 [DOI: 10.1109/TASE.2018.2886031]
- Yang H, Mei S, Song K Y, Tao B and Yin Z P. 2018b. Transfer-learning-based online Mura defect classification. IEEE Transactions on Semiconductor Manufacturing, 31(1): 116-123 [DOI: 10.1109/TSM.2017.2777499]
- Yang H, Song K Y, Mei S and Yin Z P. 2018a. An accurate Mura defect vision inspection method using outlier-prejudging-based image background construction and region-gradient-based level set. IEEE

- Transactions on Automation Science and Engineering, 15 (4): 1704-1721 [DOI: 10.1109/TASE.2018.2823709]
- Yang H, Zhou Q Y, Song K Y and Yin Z P. 2021. An anomaly feature-editing-based adversarial network for texture defect visual inspection. IEEE Transactions on Industrial Informatics, 17 (3): 2220-2230 [DOI: 10.1109/TII.2020.3015765]
- Yang Q, Zhao Y Q, Zhang F and Liao M. 2022. Automatic segmentation of defect in high-precision and small-field TFT-LCD images. Laser and Optoelectronics Progress, 59 (12): 1215008 (杨勃, 赵于前, 张帆, 廖苗. 2022. 高精度小视野 TFT-LCD 图像异物缺陷自动分割. 激光与光电子学进展, 59 (12): #1215008 [DOI: 10.3788/LOP202259.1215008])
- Yun J W, Gu H, Kim D H, Moon H S and Ko S J. 2014. Automatic Mura inspection using the principal component analysis for the TFT-LCD panel//Proceedings of 2014 IEEE International Conference on Consumer Electronics. Taipei, China: IEEE: 109-110 [DOI: 10.1109/ICCE-TW.2014.6904008]
- Zeng Y. 2017. Research of Key Technologies for TFT-LCD Display Defects Detection System Base on Machine Vision. Yueyang: Hunan Institute of Science and Technology (曾毅. 2017. 基于机器视觉的液晶屏点灯缺陷检测系统关键技术研究. 岳阳: 湖南理工学院)
- Zhang T D, Lu R S and Zhang S Z. 2016. Surface defect inspection of TFT-LCD panels based on 2D DFT. Opto-Electronic Engineering, 43 (3): 7-15 (张腾达, 卢荣胜, 张书真. 2016. 基于二维 DFT 的 TFT-LCD 平板表面缺陷检测. 光电工程, 43 (3): 7-15 [DOI: 10.3969/j.issn.1003-501X.2016.03.002])
- Zhang Y and Zhang J. 2006a. Automatic blemish inspection for TFT-LCD based on polynomial surface fitting. Opto-Electronic Engineering, 33 (10): 108-114 (张昱, 张健. 2006a. 基于多项式曲面拟合的 TFT-LCD 斑痕缺陷自动检测技术. 光电工程, 33 (10): 108-114 [DOI: 10.3969/j.issn.1003-501X.2006.10.021])
- Zhang Y and Zhang J. 2006b. Application of fuzzy expert system in defect inspection of TFT-LCD. Journal of Optoelectronics·Laser, 17 (6): 719-723 (张昱, 张健. 2006b. 模糊专家系统在 TFT-LCD 缺陷检测中的应用. 光电子·激光, 17 (6): 719-723 [DOI: 10.3321/j.issn:1005-0086.2006.06.018])
- Zhou Z H. 2016. Machine Learning. Beijing: Tsinghua University Press (周志华. 2016. 机器学习. 北京: 清华大学出版社)
- Zhu H D, Huang J C, Liu H W, Zhou Q W, Zhu J Q and Li B Q. 2022. Deep-learning-enabled automatic optical inspection for module-level defects in LCD. IEEE Internet of Things Journal, 9 (2): 1122-1135 [DOI: 10.1109/JIOT.2021.3079440]

作者简介

林思媛,女,硕士研究生,主要研究方向为图像处理与机器视觉。E-mail: lsy_0601@nuaa.edu.cn

吴一全,通信作者,男,教授,博士生导师,主要研究方向为遥感图像处理与理解、红外目标检测与识别、视觉检测与图像测量、视频处理与智能分析。E-mail: nuaaimage@163.com